

Introducción a Ciencia de Datos

Ciencia de Datos


Método científico tanto en el diseño de la solución, como en la implementación de la misma.

Para probar hipótesis.


Un producto de datos no solamente es un modelo, es un sistema complejo



Problema



Modelo



Tecnología

¿Cómo funciona un modelo de Ciencia de Datos?

Entrenamiento
(creación de modelo)

Prueba
(validación)

Producción
(uso de modelo)

Diagram showing a table with columns and rows. The columns are labeled: Name, Team, Number, Position, Age. The rows are labeled: 0, 1, 2, 3, 4, 5, 6. The data is as follows:

	Name	Team	Number	Position	Age
0	Avery Bradley	Boston Celtics	0.0	PG	25.0
1	John Holland	Boston Celtics	30.0	SG	27.0
2	Jonas Jerebko	Boston Celtics	8.0	PF	29.0
3	Jordan Mickey	Boston Celtics	NaN	PF	21.0
4	Terry Rozier	Boston Celtics	12.0	PG	22.0
5	Jared Sullinger	Boston Celtics	7.0	C	NaN
6	Evan Turner	Boston Celtics	11.0	SG	27.0

```
from sklearn.ensemble import RandomForestClassifier
classifier = RandomForestClassifier(n_estimators=100, random_state=1234)
classifier.fit(X_train, y_train)
y_score = classifier.predict_proba(X_test)
```

A Random forest algorithm



Input: GWAS dataset with M SNPs to analyze
t: number of trees to build

Output: An ensemble of trees

For i=1 to t:

- Select a bootstrap sample from the GWAS dataset
- Grow a tree from the bootstrapped data, by repeating the following steps for each terminal node of the tree:
 1. Select a random subset of variables from the bootstrap sample
 2. Find the variable that best splits the data into homogeneous groups
 3. Split the terminal node into two child nodes

End for



¿Qué NO es ciencia de datos?

- No es una tecnología
- No es una herramienta
- No es desarrollo de software
- No es *Business Intelligence*
- No es (únicamente) *Big Data*
- No es (únicamente) Inteligencia Artificial
- No es (únicamente) *machine learning*
- No es (únicamente) visualización
- No es (únicamente) hacer modelos

... pero las utiliza a todas para entregar resultados

Mitos: *machine learning* es...

... la única manera de resolver problemas

- Problemas determinísticos y problemas con soluciones analíticas pueden no necesitar modelos de ML.
- El desarrollo de modelos de ML puede ser costoso en tiempo y recursos.
- Los modelos de ML dependen de datos abundantes y etiquetados.

... agnóstico a los datos

- Los modelos de machine learning pueden absorber los sesgos presentes en los datos de entrenamiento, lo que resulta en predicciones sesgadas.
- La calidad de los resultados depende del valor y la calidad de los datos de entrada. (*garbage in, garbage out*)

... independiente del contexto

- La interpretación de los resultados y las predicciones requieren comprender el problema desde el origen de los datos hasta la temporalidad y posible interacción entre variables
- Las variables utilizadas en los modelos deben seleccionarse de manera cuidadosa, de la mano de expertos en el contexto

Componentes de ML

Datos

Información recopilada
y estructurada

Modelos

Algoritmos diseñados para
capturar patrones en los datos
y/o generar predicciones

Métricas

Medidas cuantitativas utilizadas para
evaluar el desempeño de los modelos de en
función de sus predicciones

¿Qué queremos de un modelo?


- Poder predictivo y explicativo
- Suficientemente complejo para describir el fenómeno observado
- Suficientemente simple para generalizar en observaciones futuras

La elección del modelo depende de su propósito, además está delimitada por la disponibilidad de datos y tecnología

NO EXHAUSTIVO





	Baja	Complejidad		Alta
Propósito	- Búsqueda de patrones - Generación de hipótesis	- Predicción/ estimación de variable - Clasificación de observaciones	Minimización/ maximización de objetivo	Otros casos
Modelos comunes	<u>Segmentación</u>: sin variable objetivo - K-medias <u>Basados en reglas</u>: sin variable objetivo - Reglas de asociación Formato: <u>Modelo</u>: variable objetivo - Tipo 1 - Tipo 2 ...	<u>Regresión</u>: variables continuas/ cantidades - Regresión lineal - Series de tiempo - Árbol de regresión <u>Clasificación</u>: variables binarias / categorías - Regresión logística - Árboles de clasificación - Random Forest - Red Neuronal - Máquinas de Soporte Vectorial - K-vecinos	<u>Optimización</u>: asignación de cantidades o categorías a procesos Optimización lineal	<u>Aprendizaje Profundo</u>: redes neuronales multicapa y con estructuras complejas <u>Sistemas de recomendación</u>: Filtros colaborativos <u>Análisis de redes</u>: sin variable objetivo <u>Procesamiento de lenguaje natural</u>: con o sin variable objetivo <u>Aprendizaje por refuerzo</u>: agentes maximizando recompensas

Pipeline común de un producto de ciencia de datos



Existen una infinidad de ejemplos de ciencia de datos en política pública:

- Sistemas de alerta temprana
- Priorización de recursos (inspecciones)
- Causalidad
- Optimización
- Detección de anomalías
- ...




¿Por qué ahora?

Datos en todos lados

Ámbito	Publicidad	Compras	Contenido
Grandes jugadores	 	 	 
¿Qué modelos usan probablemente?	Análisis de redes Optimización	Filtros colaborativos Reglas de asociación	Sistemas de recomendación híbridos

Cómputo *on-demand*



FALLING COST OF COMPUTE AND STORAGE⁴ (IN DOLLARS)



Fuente: *Cloud Computing: The Digital Infrastructure Powering Today's Businesses* en globalxleaves.com

Boom de la Inteligencia Artificial

Number of AI papers on Scopus by subcategory (1998-2017)
Source: Elsevier



Fuente: 1 AI Index Report 2018, 2 deviq.io

Dataset vs computer memory and computational power

Década	Datos representativos (orden de magnitud de filas)	Memoria	Cálculos/Segundo
1970	Iris (100)	1Kb	100 KF (Intel 8080)
1980	Boston (1k)	100 Kb	1 MF (Intel 80186)
1990	<i>Opt chart recog</i> (10K)	10 MB	10 MF (Intel 80486)
2000	Páginas web (10M)	100 MB	1 GF (Intel Core)
2010	<i>Advertising</i> (10G)	1 GB	1 TF (Nvidia C2050)
2020	Redes Sociales (1T)	100 GB	1 PF (Nvidia DGX-2)

Data Science Project Lifecycle




Figure 1: Lifecycle of a data science project. The phases of real projects are highly interconnected, with insights from later phases informing and revising earlier ones, resembling more of a “web” than a typical linear pipeline or cycle. Bold arrows show more frequent transitions typically repeated multiple times in the course of a project.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Oficiales de Salud pública identifican tasas elevadas de envenenamiento por plomo en niños y niñas de su jurisdicción. La práctica actual de remediar las causas ocurre luego de que un infante ha tenido una prueba positiva de niveles elevados de plomo en la sangre.

A los oficiales les gustaría reducir los casos de envenenamiento por plomo en los niños y niñas de manera proactiva al identificar los infantes que podrían estar en riesgo antes de que el envenenamiento ocurra.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Una sesión de formulación (*scoping*) es convocada con la participación de oficiales de salud pública, médicos, equipos de inspectores de riesgo de plomo (*lead hazard inspectors*) y científicos de datos.

Debido a la necesidad de trabajar con datos de salud privados y datos relacionados con niños se toma la decisión de realizar todo el trabajo analítico en el ambiente computacional seguro del Departamento de Salud Pública.

La principal intervención identificada es realizar inspecciones en hogares de gran riesgo de tener plomo y que tengan presencia de infantes menores a 12 meses. La meta identificada en esta fase de *scoping* es reducir, de manera efectiva, el envenenamiento de infantes por plomo de una manera equitativa a lo largo de las comunidades vulnerables

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

El Departamento de Salud Pública de la ciudad, provee acceso a la base de datos y a un servidor para realizar el análisis.

La base de datos incluye resultados de pruebas de sangre a nivel individual. También incluye reportes de inspección de hogares. Fuentes de datos adicionales son agregadas al ambiente: datos censales, programas de beneficios de nutrición (para identificar infantes vulnerables), información sobre edificios y hogares. Normalización de direcciones y geocodificación será unido a las fuentes de datos.

Los científicos de datos trabajan cercanamente con los dueños de las fuentes de datos para entender como los datos son generados y la estructura de los mismos.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Los científicos de datos usan una combinación de estadística descriptiva, correlaciones, análisis espacial y temporal para entender las relaciones de los datos y sus limitaciones . Valores faltantes en los datos del programa de beneficios de nutrición, ayudan a identificar un error en el proceso de ETL, el cual es corregido con una nueva extracción de datos. En otro análisis se detectó una fuerte caída en el número de pruebas de sangre en datos con más de 17 años de antigüedad, lo cual refleja un cambio de política respecto a las pruebas, que indican un límite en qué tan atrás podemos ir en entrenamiento.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Usando lo que se aprendió explorando los datos, los científicos de datos, junto con los oficiales de salud pública formulan un problema de clasificación al nivel de dirección (entidad), usando los niveles de plomo arriba de un nivel específico, como etiqueta (*label*). Scores de riesgo son generados mensualmente para cada hogar (unidad de predicción) con un niño menor de 12 meses (cohorte). La generación de *scores* es mensual, ya que corresponde con el ciclo de planeación de inspecciones del departamento.

La evaluación será usando la precisión en las 250 direcciones, consistente con la capacidad mensual del número de inspecciones que puede realizar el departamento de salud pública de la ciudad. La métrica debe incluir que las comunidades vulnerables estén representadas (*false omission rate*).

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Los científicos de datos corren una malla de miles de modelos, incluyendo varias familias de clasificadores e hiperparámetros. Basado en la habilidad de alcanzar gran precisión y balancear el *false omission rate* a lo largo de raza y estatus socioeconómico, un bosque aleatorio fue elegido para la prueba de campo.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Una prueba de campo de un año, en el cual el 50% de las 250 direcciones seleccionadas al azar son inspeccionadas por la presencia de plomo, y se realizaron reparaciones si hay riesgo de contaminación con plomo. La prueba confirmó el desempeño del modelo para identificar infantes en riesgo de envenenamiento con plomo y de su representación a lo largo de las diversas comunidades.

I. Identificación del problema

II. Formulación (*Scoping*)

III. Adquisición de datos

IV. Exploración

V. Formulación analítica

VI. Análisis/modelado

VII. Validación y prueba de campo

VIII. Acción

Aunque el número de hogares fue pequeño para tener un impacto en el número de infantes envenenados durante el periodo de prueba, se realizaron cálculos sugieren que el impacto sería mayúsculo en la siguiente década.

El Departamento de Salud Pública decide poner el modelo en producción y compromete los recursos para mantenerlo funcionando y reentrenarlo y reevaluarlo.

Una gran parte de los modelos de ciencia de datos no realizan su potencial por falta de acción/implementación, pues esta suele verse como una etapa distinta a la de la creación del modelo.

Pasos



1. ¿Cuáles son la(s) meta(s) de este proyecto?

- Es el paso más importante del proceso.
- 90% de tus usuarios/clientes/*partners* iniciarán con la definición de un problema de manera general y vaga.
- Nuestra responsabilidad es ir haciendo más concreta y refinada la definición, lo cual sucede en varias iteraciones.
- Lo más importante es hacer el objetivo concreto, medible y optimizable.
- Cuando vamos refinando el objetivo(s) es común que vayamos priorizando y por lo tanto tendremos que tener *tradeoffs* que irán muy ligados a las acciones y al contexto de negocio o impacto social.

Pasos



2. ¿Qué acciones o intervenciones existen que serán mejoradas a través de este proyecto?

- Deben ser acciones concretas, si no definimos acciones en el *scoping* no será implementada la solución, y por lo tanto no estamos haciendo ciencia de datos.
- El proyecto de ciencia de datos ayudará a tener mejor información para llevar a cabo esas acciones.
- Puede que estas acciones no existan aún en la organización, nuestro proyecto puede ayudar a generar nuevas acciones
- ¡Enumerar la lista de acciones ayuda a que el proyecto sea accionable!

Pasos



3. ¿Qué datos tenemos y cuáles necesitamos?

- ¡No hablamos de datos sino hasta el paso 3! Esto es porque debemos primero pensar en el problema, entenderlo y luego ver con qué datos contamos para resolverlo. Si hacemos esto primero seguramente acabaremos desarrollando productos de datos "muertos" y no "accionables" ... eso no es ciencia de datos.
- Queremos conocer cómo se guardan los datos, con qué frecuencia, en qué formato, en qué estructura, qué granularidad tiene, desde cuándo tenemos historia de estos datos, hay un sesgo en su recolección, con qué frecuencia recolectan nueva información, si sobrescribe la ya existente, etc.
- El objetivo consiste en identificar si la granularidad, frecuencia y horizonte de tiempo en los datos corresponde a la granularidad, frecuencia y horizonte de tiempo de las acciones.
- También debemos identificar las fuentes externas que podemos ocupar datos abiertos y si es necesario comprar datos que nos permitan enriquecer los datos internos con los que contamos.

Pasos



4. ¿Cuál es el análisis que necesitamos hacer?

- Definir qué tipo de análisis necesitamos hacer con los datos con los que contamos para cumplir con los objetivos definidos y generar las acciones identificadas.
- El análisis puede -seguramente- incluir métodos y herramientas de diferentes disciplinas: ciencias computacionales, ciencia de datos, *machine learning*, estadística, ciencias sociales.

En este paso debemos responder las siguientes preguntas:

- + ¿Qué tipo de análisis necesitaremos? Puede ser más de uno
- + ¿Cómo vamos a validar el análisis? ¿Qué validaciones se pueden hacer con los datos existentes?
- + ¿Cómo podemos diseñar una prueba en campo para validar el análisis antes de que hagamos despliegue?
- + Identificar qué acciones se cubren con cada análisis <- debemos tener todas las acciones cubiertas.

Reportes

Los entregables más básicos, describen los resultados obtenidos o esperados a futuro. Estos reportes también suelen ser preparados para ser presentados a los patrocinadores del proyecto y líderes de la organización.

Es común construir tableros (*dashboards*) accesibles internamente, los cuales también permiten actualizaciones en vivo, para facilitar el acceso a todas las áreas que se benefician.

Software integrado en sistemas existentes

Considera integrar los resultados del modelo, y posiblemente predicciones para nuevas observaciones, en bases de datos o sistemas operativos existentes. Este entregable minimiza la necesidad de aprendizaje para los usuarios.

Por ejemplo, si en una empresa un modelo fue creado para recomendar un producto financiero a los clientes de un banco, este podría ser incluido en los sistemas de CRM para que los vendedores tengan acceso directo a tal sugerencia.

Software independiente

Un equipo especializado en desarrollo de software crea una solución, generalmente un programa ejecutable o una app, que permita utilizar los resultados del modelo.

Dado que no es necesaria la integración con sistemas operativos, la solución puede ser implementada más rápidamente; sin embargo, necesita un esfuerzo considerable de desarrollo, mantenimiento y aprendizaje.

Para obtener el impacto de cualquier modelo de ciencia de datos, este tiene que ser implementado.

La implementación debe ser planeada y construida por los roles adecuados dentro de la organización.

Obstáculos comunes a para lograr un cambio organizacional que permita tomar decisiones basadas en ciencia de datos

Organización

Aislamiento

Los roles de experiencia y técnicos deben trabajar en conjunto y comunicarse, en todas las fases. Plantear el proyecto sin consultar a los técnicos suele resultar en promesas inalcanzables (ya sea de desempeño, de tiempos o de tecnología). Por otro lado, trabajar sin estrategia suele crear acumulación de análisis y modelos.

Desconexión

Incluso el modelo con las mejores métricas técnicas de desempeño, no tiene valor si no está ligado a métricas que puedan analizar el impacto generado. Sin embargo, el impacto suele verse realizado en áreas diferentes, así que debe hacer mecanismos correctos de atribución.

Acumulación

La creación indiscriminada de tableros, reportes o incluso modelos, con más métricas de las que se pueden monitorear efectivamente, suele quitar mérito y prevenir la obtención de impacto. Durante el planteamiento de cualquier proyecto de ciencia de datos, es necesario considerar tanto la audiencia como la implementación.

Liderazgo

Estrategia vaga

Instruir al equipo de ciencia de datos que “haga algo con los datos de los usuarios” o “use *big data*” supone que esta área priorizará los problemas de negocio a ciegas, lo cual suele desembocar en desacuerdos posteriores con los líderes. Este fenómeno es especialmente prevalente con las *buzzwords*.

Descentralización

Las organizaciones necesitan una Plataforma centralizada que integre las múltiples fuentes de datos y permita acceso a todas desde un mismo punto. Si los datos no se encuentran centralizados, agregarlos y controlarlos de manera efectiva en tiempo real; o tener modelos de ciencia de datos en producción, es imposible.

Sesgo

Independientemente del sesgo en los datos, el sesgo en la estrategia debe ser motivo de reflexión. Buscar la confirmación de hipótesis sin explorar otras posibles tendencias en los datos, o ignorar/cambiar datos que muestren tendencias contrarias a las iniciales, merma el esfuerzo de tomar decisiones basadas en datos.

Tecnología

Estancamiento

Al igual que en la cocina es preferible usar el cuchillo correcto para diferentes fines, cada problema en una organización será mejor resuelto con ciertos modelos de ciencia de datos. Algunas veces, los roles técnicos buscan utilizar el mismo modelo complejo para todos los problemas, potencialmente sacrificando mejoras.

Expectativas incorrectas de roles

Cada uno de los roles son diferentes y necesarios para una construcción e implementación de un modelo de ciencia de datos. Para que un equipo funcione correctamente, es necesario distribuir las tareas correctamente a los roles correspondientes; sin esperar “unicornios” que posean todas las habilidades.

Jerga técnica

Si los líderes o usuarios no pueden entender los modelos, es poco probable que las soluciones se implementen exitosamente. Los roles técnicos, especialmente los científicos de datos, deben aprender a “contar historias” y a crear visualizaciones poderosas para estructurar su comunicación de manera efectiva con distintas audiencias.

Este no es el típico curso de ML...

Se dejará en manos de los expertos...

- La teoría de los algoritmos y su construcción desde cero
- Las suposiciones detrás de los algoritmos de ML
- La calibración de parámetros e hiperparámetros
- La modificación de los algoritmos

Más bien se priorizará...

- Leer y manipular bases de datos
- Consumir modelos
- Definir un proyecto de ciencia de datos
- Usar herramientas modernas para el análisis de datos
- Entender cómo CD se distingue y qué cambios hay que hacer en tu organización
- *Unlock* nuevas preguntas y herramientas para resolver problemas reales

Herramientas a usar

Para que cualquier tecnología alcance su potencial, debe de ser bien entendida, bien documentada y soportada por herramientas maduras y con soporte.



Plataforma de servicios en la nube que permite acceder a la misma infraestructura tecnológica, con el tamaño y capacidad que se requiera, sin necesidad de usar hardware físico



Plataforma de servicios en la nube que permite acceder a la misma infraestructura tecnológica, con el tamaño y capacidad que se requiera, sin necesidad de usar hardware físico



Base de datos relacionales de código abierto que permite centralizar el almacenamiento, consultar y preprocesar datos

Ejercicios / Tarea

1. Llena [este formulario](#) con tus datos
2. Llena [este formulario](#) para poder crear tus conexiones a la infraestructura de cómputo en la nube de la Escuela

En “grupo de investigación” escribe “Clase Ciencia de Datos”

2. Cada semana llena [esta encuesta](#)