

Bases de Datos

¿Qué son los datos?

Idealmente, los datos representan eventos relacionados a entidades: ya sea que les sucedan o que actúen en ellos.

Los datos indican el qué de quién en dónde y cuándo.

atributo

entidad

ubicación

¿Qué son los datos?

- Prácticamente todas nuestras interacciones con el mundo generan datos, pero es importante saber analizarlos para tomar decisiones informadas
- Lo primero que se viene a la cabeza son tablas con filas y columnas
- sin embargo, la mayor parte de los datos que se producen en el mundo no siguen reglas estrictas de formato.

¿Qué *queremos*
hacer con los datos?

- Guardarlos
- Consultarlos
- Entender/Justificar
- Predecir
- Optimizar
- Detectar
- Representarlos

¿Qué **podemos**
hacer con los datos?


- Filtrar
- Seleccionar
- Transformar
- Mutar
- Agrupar/Reducir
- Unir

Primera regla de los datos

INMUTABILIDAD


i.e. “lo pasado, pasado”

Datos estructurados y no estructurados



Datos Estructurados

*Datos cuantitativos:
tablas con números y valores*



Datos No Estructurados

*Datos cualitativos:
documentos de texto, audio, video, etc.*

Origen	Transacciones, sensores, formas en línea, logs	Correos electrónicos, documentos de texto, imágenes, videos
Formatos	Excel, SQL	Multimedia (mp3, mp4, pdf), NoSQL
Almacenamiento	Bases de datos relacionales o <i>data warehouses</i> , los cuales tienen estructura predefinida y requieren preprocesamiento	<i>Data lakes</i> , los cuales guardan los datos en su formato nativo y no los procesan hasta que es necesario analizarlos

Existe un tercer tipo de datos, semi-estructurados (e.g., JSON, CSV, XML). Generalmente almacena “metadatos”, que identifican características diferenciadoras de los datos para permitir un mayor catalogamiento y búsqueda de ellos.

Unstructured data

The university has 5600 students.
John's ID is number 1, he is 18 years old and already holds a B.Sc. degree.
David's ID is number 2, he is 31 years old and holds a Ph.D. degree. Robert's ID is number 3, he is 51 years old and also holds the same degree as David, a Ph.D. degree.

Semi-structured data

```
<University>
  <Student ID="1">
    <Name>John</Name>
    <Age>18</Age>
    <Degree>B.Sc.</Degree>
  </Student>
  <Student ID="2">
    <Name>David</Name>
    <Age>31</Age>
    <Degree>Ph.D. </Degree>
  </Student>
  ....
</University>
```

Structured data

ID	Name	Age	Degree
1	John	18	B.Sc.
2	David	31	Ph.D.
3	Robert	51	Ph.D.
4	Rick	26	M.Sc.
5	Michael	19	B.Sc.

Datos Estructurados

Tipos comunes

Todos los datos estructurados, por definición, deben poder representarse en tablas con filas y columnas. Además, cada celda debe contener solamente un dato, ya sea numérico, carácter, fecha, etc.



Datos de cliente



Histórico de inventario



Transacciones



Fechas



Catálogos



NPS/CSAT



Bases de datos



Hojas de cálculo planas¹

Los datos estructurados suelen requerir poco procesamiento para ser utilizados, por ejemplo para crear reportes organizacionales.

Pros

- Facilidad de uso por usuarios de negocio
- Facilidad de uso para modelos de ciencia de datos
- Accesibilidad con una gran variedad de herramientas

Contras

- Uso limitado al propósito para el que fueron creados
- Dificultad para realizar cambios en almacenamiento ante cambio de estructura

¹Aunque los archivos de Excel están organizados en filas y columnas, no todos son equivalentes a una tabla. Solamente aquellos que no incluyen información extra, celdas combinadas, tablas dinámicas, gráficas, etc. pueden ser considerados como datos estructurados.

Datos Estructurados: Herramientas comunes



Los sistemas de bases de datos relacionales permiten tanto cargar y almacenar datos masivos en tablas relacionadas entre ellas, tanto realizar consultas rápidamente.



Los sistemas ERP (*enterprise resource planning*, planeamiento de recursos de la empresa) son un tipo de software que las organizaciones utilizan para administrar las actividades comerciales cotidianas, como contabilidad, adquisiciones y operaciones de la cadena de suministro.



Los sistemas de administración de bases de datos multi-modales están diseñados para contener datos con modelos diferentes, ya sean relacionales, documentos, etc.



Los sistemas de CRM (*customer relationship management*, administración de la relación con los clientes) centralizan datos de los clientes actuales o prospectos, sus transacciones, y provee acceso a colegas con contacto directo.

Datos No Estructurados

Tipos comunes

Estos datos no tienen una estructura o formato definido.



E-mail



Logs



Chats



Encuestas




Audio



Sensores



Imágenes



Contenido de
redes sociales



Quejas y
sugerencias



Videos



Notas (e.g. servicio al
cliente, diagnósticos)

Pros

- Almacenamiento directamente desde la fuente
- Acumulación rápida dada la flexibilidad en el formato

Contras

- Necesidad de alto grado de conocimiento por parte de los usuarios, ya sea de negocio o de creación de modelos
- Limitación a herramientas especializadas para análisis

La mayor parte de los datos producidos en el mundo son no estructurados.

En general, deben ser procesados para ser convertidos en datos estructurados que puedan ser utilizados en modelos.

Datos No Estructurados: Herramientas Comunes



Es un conjunto de utilidades de software que permiten el uso de una red de muchas computadoras para almacenar o procesar datos. Permite almacenamiento distribuido y procesamiento de *big data*.



Comprende una variedad de servicios de almacenamiento, estructurado como un *data lake* para proveer soporte para cualquier formato de datos. Permite interconexión con otros servicios de Microsoft.




Está basado en documentos tipo JSON, y está orientado a almacenar documentos. Especialmente útil para procesamiento de lenguaje natural.



Es un sistema de administración de bases de datos de grafos. Una base de datos de grafos contiene nodos, bordes y propiedades en vez de filas y columnas.

Formatos



Retos

ID	Nombre	CP	Ciudad	Estado	Salario
1	Green	60610	Chicago	IL	30k
2	Green	60611	Chicago	IL	32k
3	Peter		New Yrk	NY	40k
4	John	11507	New York	NY	40k
5	Paul	90057	Los Angeles	CA	55k
6	Chuck	90057	San Francisco	CA	30k

¿duplicado?

error

valor faltante

violación de restricción

Procesamiento: reglas de dedo

1. Absorbe y preserva modalidades
2. Reduce la pérdida entrópica de información hasta el final
3. Modela la temporalidad inherente de los datos (bitemporalmente)
4. Data provenance
5. Preserva/ Registra la intencionalidad de los pasos
6. Cada paso de la transformación hace visible qué está pasando