

Modelos de clasificación desde cero

Árboles de decisión

Ejemplo 1: Titanic



Titanic

Utilizar un modelo de Aprendizaje Automático para predecir los sobrevivientes al hundimiento del Titanic.

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.0750	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S

PassengerId Unique ID of the passenger

Pclass Passenger's class (1st, 2nd, or 3rd)

Name Passenger's name

Sex Passenger's sex

Age Passenger's age

SibSp Number of siblings/spouses aboard the Titanic

Parch Number of parents/children aboard the Titanic


Ticket Ticket number

Fare Fare paid for ticket

Cabin Cabin number

Embarked Where the passenger got on the ship (C - Cherbourg, S - Southampton, Q = Queenstown)

Titanic – lo que nos diría la ficción



Titanic – lo que nos dicen los datos


Si hacemos el análisis exploratorio de los datos:

Parece que sexo sí es un buen predictor de haber sobrevivido, pero la diferencia por edad para hombres no es muy grande.

¿Qué podríamos hacer para buscar una mejora?

- Cambiar el límite de 10 años a otro número
- Escoger otra variable

Ejercicio en clase: utiliza el notebook “ML Teoria” para explorar estas dos opciones.



Discusión - ¿qué encontraron? ¿cuál(es) variables separan “bien” a los sobrevivientes?

Los árboles de decisión realizan el mismo proceso de buscar variables que separen “bien” a la variable a predecir... pero automáticamente. Busca variables “puras”.


Una variable completamente pura, o con una entropía alta, o con una desigualdad alta, tendría perfectamente separados los “-” y los “+” en la gráfica de la derecha.


El algoritmo de árbol de decisión busca primero, la variable más pura para toda la población. Luego, para cada una de las subpoblaciones que quedan al separarla por la primera variable, busca las respectivas nuevas variables más puras. Hace este proceso iterativamente.

Definición técnica por Entropy (C. Shannon, 1948):

$$Entropy = - \sum p_i \log(p_i)$$

donde p_i es el porcentaje relativo (probabilidad).






Algoritmo

1. Obtener la entropía de la variable a clasificar
2. Obtener la entropía de la variable a clasificar con respecto a una variable predictora
3. Obtener la ganancia de la variable seleccionada en el paso anterior
4. Repetir el paso 2 y 3 por cada variable predictora
5. Seleccionar la variable con mayor ganancia de información como el nodo raíz/decisión
6. Repetir los pasos 2 y 3 para el resto de las observaciones y variables cuya entropía es mayor a 0 hasta que la entropía sea 0 o bien, no haya más observaciones para dividir.


Si la entropía es 0, se trata de una hoja todos los datos son homogéneos, no hay impureza.
Si la entropía es >0 aún se debe seguir dividiendo el conjunto de datos.

La condición de paro de este algoritmo consiste en que todas las variables logren tener una entropía de 0 o bien, que ya no haya más observaciones para poder seguir dividiendo.

Nuestro árbol original



El árbol que nos da el código



Ejemplo 2: Entendamos la entropía

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Datos de ejemplo.

Contamos con 10 observaciones en nuestro conjunto de datos para aprender los patrones entre la temperatura y la humedad para decidir si jugar golf o no.

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

$$Entropy = - \sum p_i \log(p_i)$$

$$Entropia(T) = -(6/10)\log_2(6/10) - (4/10)\log_2(4/10)$$

$$Entropia(T) = 0.9709506$$

Iniciamos calculando la entropía de la variable *target*.

Formulando nuestra variable *target* como una variable bernoulli, nuestro éxito corresponde a jugar golf, y el fracaso a no jugar golf.

La probabilidad de jugar golf consiste en contar la frecuencia de jugar golf entre el número de observaciones totales de nuestro conjunto de datos, esto es 6 de 10 observaciones. Mientras que la probabilidad de no jugar golf es de 4 de 10 observaciones.

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Temperatura Alta:

$$Entropia(Temp_A) = -(2/5)\log_2(2/5) - (3/5)\log_2(3/5)$$

$$Entropia(Temp_A) = 0.9709506$$

El siguiente paso consiste en obtener la entropía de nuestra variable *target* con respecto a una variable explicativa, no importa cual, pues revisaremos todas las variables explicativas.

Iniciaremos con la variable temperatura.

La variable temperatura tiene 2 valores diferentes: alta y normal, por lo que calcularemos la entropía para cada valor.

Para cuando la temperatura es alta, existen 5 observaciones, de las cuales en 2 observaciones jugamos golf y en 3 no.

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Temperatura Normal:

$$Entropia(Temp_N) = -(4/5)\log_2(4/5) - (1/5)\log_2(1/5)$$

$$Entropia(Temp_N) = 0.5931569$$

Para cuando la temperatura es normal, existen 5 observaciones, en las cuales 4 jugamos golf y 1 no.

La ganancia de información que obtenemos ocupando la temperatura para clasificar jugar golf o no:

$$Ganancia(T, Temp) = Entropia(T) - Entropia(T, Temp)$$

$$Ganancia(T, Temp) = Entropia(T) - [P(Temp_A) * Entropia(Temp_A) + P(Temp_N) * Entropia(Temp_N)]$$

$$Ganancia(T, Temp) = 0.9709506 - (5/10 * 0.9709506 + 5/10 * 0.5931569)$$

$$Ganancia(T, Temp) = 0.1888969$$

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Humedad Alta:

$$Entropia(H_A) = -(2/6)\log_2(2/6) - (4/6)\log_2(4/6)$$

$$Entropia(H_A) = 0.9182958$$

Haremos lo mismo que hicimos con la variable explicativa para la siguiente variable explicativa que tenemos, humedad.

La variable humedad tiene 2 valores diferentes: alta y normal, por lo que calcularemos la entropía para cada valor.

Para cuando la humedad es alta, existen 6 observaciones, de las cuales en 2 observaciones jugamos golf y en 4 no.

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Humedad Normal:

$$Entropia(H_N) = -(4/4)\log_2(4/4) - (0/4)\log_2(0/4)$$

$$Entropia(H_N) = 0$$

Para cuando la humedad es normal, hay 4 observaciones de las cuales las 4 están asociadas a jugar golf.

Dado que todos los elementos de esta variable ya son iguales, es decir, todos tienen el mismo valor de la variable *target*, su entropía es 0, pues todo los elementos son homogéneos.

Ahora calcularemos la ganancia de información para esta variable

$$Ganancia(T, H) = Entropia(T) - Entropia(T, H)$$

$$Ganancia(T, H) = Entropia(T) - [P(H_A) * Entropia(H_A) + P(H_N) * Entropia(H_N)]$$


$$Ganancia(T, H) = 0.9709506 - (6/10 * 0.9182958 + 6/10 * 0)$$

$$Ganancia(T, H) = 0.419973$$

Ahora que ya tenemos la entropía que aporta cada variable explicativa, deberemos seleccionar la que mayor ganancia de información tiene. En este caso, la humedad, por lo que esta variable se convierte en nuestro nodo raíz.

Dado que la humedad puede tomar dos valores, normal o alta, se generan dos nodos debajo del nodo raíz, uno para cuando la humedad es normal, y otro para cuando la humedad es alta.

También sabemos que en todos los casos en los que la humedad es normal la variable *target* toma el valor jugar golf, por lo que sabemos que su entropía es 0 y que todas las veces que la humedad sea normal, predicción será jugar golf.



	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Normal	Alta	Si
5	Normal	Alta	No
6	Normal	Alta	Si

Ahora calcularemos la entropía con el resto de las observaciones, esto es, cuando la humedad es alta.

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Normal	Alta	Si
5	Normal	Alta	No
6	Normal	Alta	Si

Temperatura Alta:


$$Ganancia(T|A, Temp) = -(0/3)\log_2(0/3) - (3/3)\log_2(3/3)$$

$$Ganancia(T|A, Temp) = 0$$

Regresamos al paso 2 para calcular la entropía con el resto de las variables explicativas con el nuevo subconjunto de observaciones, por lo que calcularemos la entropía con la temperatura.

Cuando la temperatura es alta, tenemos 3 observaciones, sin embargo, en todas las observaciones la variable *target* toma el valor de no jugar golf, por lo que al calcular la entropía, ésta se vuelve 0, porque todos los elementos de este subconjunto son homogéneos, es decir, tienen el mismo valor.

Dado que ya no tenemos más variables explicativas para verificar, podemos parar el algoritmo y ver el árbol generado:



Cuando la humedad es normal, el árbol regresará como predicción jugar golf.


Si la humedad es alta, verificamos qué valor tiene la temperatura, si ésta es alta, el árbol regresará como predicción no jugar golf.

Por último, si la humedad es alta, y el valor de la temperatura es normal el árbol regresará como predicción jugar golf.

La razón asociada a esta predicción es porque en el último paso que ejecutamos, en dos de las tres observaciones que tenían temperatura normal, la etiqueta *target* tenía el valor jugar golf.

Sobreajuste/overfitting

Si dejas que el árbol crezca sin limitar la profundidad es muy probable que hagas un modelo sobre ajustado, y por otro lado, si limitas la profundidad a ser muy pequeña, es muy probable que sub ajustes el modelo por lo que no generalizará correctamente los patrones en los datos.



KNN – *k nearest neighbors*

Idea general


En este algoritmo, la fase de aprendizaje o entrenamiento consiste en tomar las observaciones con las que quieres aprender.

Este método realiza la predicción basada en lo que opinan los k vecinos más cercanos a la nueva observación.

¿Cómo definimos cercanía?

¿Qué es la distancia?

En KNN definimos **cercanía** calculando la *distancia euclidiana*, aquellos con menor distancia son los que están más cercanos –más similares- a mí:



¡Cada *feature* en nuestro conjunto de datos corresponde a una dimensión!

One hot encoding

Debido a que necesitamos distancia, requerimos que los *features* que ocupamos para hacer la clasificación sean *todos* de tipo numérico.

Aquellas variables que no sean numéricas deberán convertirse a *One hot encoding* (dummy).


Esta transformación de datos permite convertir datos categóricos a datos numéricos al cambiar su codificación a un valor binario. Para realizar esta transformación, se requiere de crear n columnas correspondientes a los n valores diferentes que puede tomar la variable categórica, para después indicar qué valor tiene la observación. Por ejemplo:

id	color	edad
1	azul	24
2	azul	28
3	morado	5
4	amarillo	26
5	verde	45



id	color_amarillo	color_azul	color_morado	color_verde	edad
1	0	1	0	0	24
2	0	1	0	0	28
3	0	0	1	0	5
4	1	0	0	0	26
5	0	0	0	1	45

Ejemplo - iris




Discusión: usando solamente estas dos variables, ¿cómo clasificarían a cada una de las nuevas observaciones?

Ejercicio en clase: utiliza el notebook “ML_Teoría” para explorar si tu opinión cambia al usar pares diferentes de variables.

Ejemplo – iris

Resultados de KNN con $k = 3$



Ejercicio en clase: utiliza el notebook
“ML_Teoría” para explorar si tu las predicciones
cambian considerablemente al tomar más (o
menos) vecinos.

Árboles de decisión

Ventajas

- Es muy fácil de implementar e interpretar.
- Se pueden ocupar tanto variables explicativas numéricas como variables explicativas categóricas.
- Se pueden visualizar las reglas del árbol.

KNN

- Fácil de implementar
- Hay diferentes distancias que se pueden ocupar dependiendo del problema

Desventajas

- Caro computacionalmente
 - Hay que calcular la distancia de cada nueva observación a todas las existentes en el proceso de aprendizaje.
 - Si olvidas escalar los datos puedes obtener predicciones diferentes.
 - ¿Qué k es mejor?
-
- Dependiendo de qué variables explicativas incluyas en tu modelo, el árbol puede dar resultados muy diferentes.
 - Es fácil sobre ajustar el modelo al dejarlo crecer en profundidad sin hacer /pruning/.
 - Definir los hiperparámetros para la profundidad y el número de elementos que un nodo debe tener para ser considerado hoja, dependen de la experiencia del que desarrolla el modelo y del problema en particular.