

Algunos modelos tienen coeficientes explícitos, que generalmente describen una relación directa e independiente de las variables con el resultado

Ejemplos de interpretación de coeficientes

Regresión lineal

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

Se interpreta β_j como el efecto directo en Y de incrementar X_j en una unidad, manteniendo las demás X constantes. El signo del coeficiente indica una relación positiva o negativa respectivamente.

El coeficiente β_0 se conoce como *intercepto*, y es un valor base independiente de los efectos de las variables X en Y .

Regresión logística

$$Y = \frac{1}{1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon}}$$

Se interpreta β_j como el efecto multiplicativo en Y de incrementar X_j en una unidad, manteniendo las demás X constantes. Además, como Y es un valor entre $[0,1]$, generalmente se representa como un efecto en probabilidad.

El coeficiente β_0 se conoce como *intercepto*, y es un valor base independiente de los efectos de las variables X en Y .

Es importante recordar la regla de oro: correlación no implica causalidad.

Existe una alta correlación entre ventas de helado y ataques de tiburón, pero ninguno de estos dos fenómenos causa el otro: ambos tienen que ver con un aumento en temperatura por el verano.


Algunos modelos, especialmente los más complejos, no tienen coeficientes sino medidas de importancia de variables

Importancia general en el modelo


Una manera de obtener la importancia de variables es obteniendo su valor SHAP promedio.

Es importante mencionar que las métricas de importancia de variables no deben ser interpretadas como coeficientes, sino como índices comparables solamente entre ellos.

En modelos no lineales (como árboles de decisión, redes neuronales, etc.) las métricas de importancia no indican una correlación, y no es posible concluir de ellas impacto positivo o negativo de una variable en el resultado.



Importancia para cada observación





Los valores SHAP interpretan el impacto de tener un valor específico para cada variable, en comparación con la predicción que resultaría si tal variable tomara un valor de línea base.

Proporcionan un grado de interpretabilidad a nivel individuo/observación (por ejemplo, si una decisión de otorgamiento de préstamo es negativa, es posible obtener la lista de variables con mayor impacto en tal decisión).



Desempeño de modelos

¿Cuál modelo es mejor?





¿Por qué?

¿Cuál modelo es mejor?



¿Por qué?

¿Cuál modelo es mejor?




¿Por qué?

Desempeño de modelos de regresión

En general, hay dos tipos de métricas de desempeño de modelos: de regresión y de clasificación

Modelos de regresión

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$




Dado que se busca predecir cantidades, las métricas ayudan a entender la correlación o el error promedio.

Métrica	Fórmula	Interpretación
Intervalos de confianza para coeficientes	$\widehat{\beta}_0 \pm 2 \cdot SE(\widehat{\beta}_0)$ $\widehat{\beta}_1 \pm 2 \cdot SE(\widehat{\beta}_1)$	Son intervalos numéricos entre los que se encuentra cada uno de los coeficientes, con cierta confiabilidad. <u>Si el intervalo de confianza de un coeficiente contiene al cero, entonces es factible que tal coeficiente no tenga ningún efecto en la variable a predecir.</u>
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$	Es la raíz cuadrada de la diferencia entre los valores predichos por el modelo y los observados. Un valor cercano a cero significaría un modelo con un ajuste perfecto. Dado que depende de valores, no es comparable entre distintos tipos de datos y es sensible a valores extremos.
R^2	$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$	R^2 es la correlación entre los valores reales y los modelados, al cuadrado. <u>Una R^2 cercana a 1 indica que el modelo explica una gran proporción de la varianza, y es preferible.</u> La R^2 siempre aumentará cuando se añadan variables al modelo, pero esto puede causar un sobreajuste (<i>overfitting</i>).

NO EXHAUSTIVO

Desempeño de modelos de clasificación

¿Todos los errores en modelos o análisis son igual de costosos?



La siguiente tabla es conocida como "matriz de confusión":

	Predicción	
	Verdadero Positivo	Falso Negativo
Valor Real	Falso Positivo	Falso Negativo

¿Cuándo es más grave un error tipo I?

Si una persona inocente está en juicio por asesinato, una sentencia errónea de culpabilidad sería devastadora para tal persona, especialmente porque el proceso para apelar es complejo y lento. En general, el sistema judicial trata de minimizar el error tipo I.

¿Cuándo es más grave un error tipo II?

Si una persona recibe un diagnóstico inicial erróneo positivo de cáncer, se le harán más pruebas, una de las cuales rápidamente desmentirá el error. Si una persona recibe un diagnóstico erróneo negativo de cáncer, este podría agravarse antes de que el error sea identificado.

Discusión: ¿en cuáles casos es más grave sobreestimar – y en cuáles, subestimar - el valor real de una variable numérica?

En general, hay dos tipos de métricas de desempeño de modelos: de regresión y de clasificación

Modelos de clasificación


Los modelos de clasificación más sencillos son binarios: predicen la pertenencia de un individuo a una categoría.

Así, existen dos tipos de error: falsos positivos (real no, predicción sí) y falsos negativos (real sí, predicción no).

Predicción \ Real	No	Sí
	No	Sí
No	TN (negativos reales)	FN (falsos negativos)
Sí	FP (falsos positivos)	TP (positivos reales)

Algunos clasificadores producen como resultado un valor entre [0,1], que se interpreta como la probabilidad de pertenencia al grupo. Cuando esto sucede, es necesario definir un valor límite: por ejemplo, cualquier observación con una predicción mayor a 0.8 es asignada al grupo. LA elección de este límite impacta las métricas de desempeño.


Dado que se busca asignar categorías, las métricas ayudan a entender las proporciones de categorías asignadas correctamente, flexibilizando que ciertos errores pueden tener más impacto que otros.

Métrica ¹	Fórmula	Interpretación
Accuracy	$\frac{TP + TN}{TP + TN + FP + FN}$	Porcentaje de observaciones categorizadas correctamente. Cuando existe un “desbalance de clases” (ej. para un modelo de detección de fraude, la gran mayoría de los datos serán legítimos), <i>accuracy</i> es una métrica engañosa.
Error tipo 1 (falsos positivos)	$\frac{FP}{TP + TN + FP + FN}$	Porcentaje de “falsas alertas”. En un clasificador es fundamental revisar esta métrica, pues generalmente existen costos diferentes ligados a falsos positivos o negativos. Por ejemplo, si las decisiones judiciales se hicieran con modelos, un falso positivo condenaría a una persona inocente.
Error tipo 2 (falsos negativos)	$\frac{FN}{TP + TN + FP + FN}$	Porcentaje de “fraudes permitidos”. En un clasificador es fundamental revisar esta métrica, pues generalmente existen costos diferentes ligados a falsos positivos o negativos. Por ejemplo, en biopsias de cáncer, un falso positivo será desmentido con los siguientes exámenes, pero un falso negativo podría tener consecuencias drásticas.
Precision	$\frac{TP}{TP + FP}$	Un modelo con <i>precision</i> alta es “puro” en sus predicciones positivas: tal vez no encuentra todos los positivos, pero aquellos con predicción positiva tienen una muy alta probabilidad de ser correctos. Generalmente un aumento en <i>precisión</i> implica una disminución en <i>recall</i> .
Recall	$\frac{TP}{TP + FN}$	Un modelo con <i>recall</i> alto es exitoso en encontrar todos los casos positivos en los datos, aunque prediga algunos casos negativos como positivos. Generalmente un aumento en <i>recall</i> implica una disminución en <i>precision</i> .
F1 score	$\frac{2 * (Precision * Recall)}{Precision + Recall}$	Combina <i>precisión</i> y <i>recall</i> para ofrecer una vista más completa de la captura de positivos en el modelo. Está diseñada para reflejar bien el desempeño de modelos con “desbalance de clases”.
AUC		La curva ROC muestra dos métricas relacionadas a los verdaderos positivos y falsos negativos, considerando todos los posibles valores límite. Un modelo mejor tendrá una curva ROC cuya curva superior izquierda se aproxima a la esquina. AUC (<i>area under the curve</i>) describe el área bajo esta curva. Un modelo que funciona igual que una moneda tirando volados tendrá un AUC = 0.5, mientras que un modelo perfecto tendría un AUC = 1.


NO EXHAUSTIVO

Los nombres de algunas métricas se conservan en inglés dado que las traducciones a español de estas métricas suelen variar, mientras que las referencias en inglés son sumamente robustas.

Curva de *precision-recall*



Curva ROC



Ejercicio en clase

ID entidad	¿Alto riesgo?	Predicción
1	Sí	No
2	No	No
3	Sí	No
5	Sí	Sí
15	No	Sí
24	No	No
35	Sí	No
47	Sí	Sí
98	Sí	No
190	Sí	Sí

Calcula e interpreta las siguientes métricas.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Error tipo 1 (falsos positivos)} = \frac{FP}{TP + TN + FP + FN}$$

$$\text{Error tipo 2 (falsos negativos)} = \frac{FN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2 * (\text{Precision} * \text{Recall})}{\text{Precision} + \text{Recall}}$$


A veces se usarán *precision@k* y *recall@k*

En cualquier problema hay recursos limitados, pero en problemas de política pública estos son más evidentes.


Imagina que sólo contamos con 100 inspectores para poder realizar inspecciones cada 6 meses. El número de inspectores que se pueden realizar es una **restricción** a la acción: **realizar la inspección**.

Para incluir estas restricciones se utilizan las métricas de desempeño *precision@k* y *recall@k*. La k está asociada a los recursos disponibles, puede ser un porcentaje o puede ser un valor entero. Por ejemplo, en el caso de los 100 inspectores, nuestra k sería 100 – solo contamos con 100 inspectores.

Precision@k mide qué tan eficientes somos utilizando los recursos mientras que *Recall@k* mide cómo estamos distribuyendo los recursos entre todos los que los necesitan.



En general, para un mismo problema, un modelo más complejo tendrá mejor desempeño, pero a un costo de interpretabilidad



Los modelos con mayor complejidad tienen mayor poder de predicción, pero también requieren considerablemente mayor volumen de datos. Mientras que una regresión lineal puede dar un resultado aceptable con 30 datos, un *random forest* sin duda estará sobreajustado.


La interpretabilidad es forzosa cuando...

- ... las decisiones impactan directamente a individuos (ej., decisión de otorgar o no un préstamo hipotecario)
- ... la salud está en juego (ej., identificación de tratamiento específico adecuado para un paciente con cáncer)
- ... el modelo debe ser aprobado por un órgano regulatorio (ej., COFEPRIS, CNBV)

Entrenamiento y prueba (*train & test*)

Nos interesa conocer el desempeño que tendría el modelo en el mundo real (datos que no ha visto antes)...

Ejemplo ilustrativo



Modelo


Desempeño teórico

Precision: 90%

Recall: 72%



Puesta en producción



Resultados


Desempeño real

Precision: 88%


Recall: 73%

... sin embargo, no necesitamos una prueba de campo, ni obtener datos nuevos


Ejemplo ilustrativo




Training



Testing/Validation



Cuando nuestros datos son temporales, generalmente la partición en *train* y *test* no será aleatoria.



¿Contra qué nos comparamos?

Baserate

- Corresponde a la tasa actual de prevalencia de lo que estamos interesado en predecir. Por ejemplo: tasa de abandono escolar.
- El valor del /baserate/ depende del momento en el que se mida <- esto será importante más adelante.
- Corresponde a la cantidad que queremos /afectar/ con la acción.

Baseline

- Es la métrica de desempeño actual (y/o de equidad) con la forma en la que se esté tratando el problema actualmente.
- **Necesitamos** tener un *baseline*, con ello podemos comparar el desempeño de nuestros modelos y saber si en verdad es una mejora a la solución actual o no.

Ejemplos de baseline:

- Inspecciones actualmente se hacen al azar.
- Inspecciones se hacen basadas en un atributo
- Inspecciones se hacen basadas en una regla o heurística


Validación de modelos

Metodologías de validación de modelos

in-sample



out-sample



k-fold cross validation















K-fold (temporal)

Usado para datos *no* temporales. Por ejemplo, clasificación de imágenes.

Comparativamente, usa más datos para entrenamiento y más *folds* que *TCV*.

En teoría, reduce la varianza en el error de las predicciones en datos *out-of-sample*.





Pregunta:

En los RF no necesitamos hacer *cross validation*, ¿por qué?.


Temporal cross validation

- Importante si los datos tienen un componente temporal
- Imita cómo el modelo será usado en el mundo real
- Computacionalmente más "barato" ya que se pueden reutilizar los *folds*
- En teoría, reduce el sesgo en los errores de las predicciones en datos *out-of-sample*




Al utilizar K-fold en un problema que implica temporalidad harás una subestimación del error mientras entrenas y validas tus modelos, porque estás viendo el futuro. <- Eso es hacer *leaking*.

Proceso:



Implementación:





Configuración temporal

- ¿Cuántos datos tienes para la creación de /features/?
- ¿Cuántos datos tienes para la generación de etiquetas?
- ¿Con qué frecuencia reentrenarás el modelo?
- ¿Cuánto tiempo para la etiqueta estará contemplado en las matrices de entrenamiento?
- ¿Cuántos renglones por entidad habrá en las matrices?
- ¿Qué tan "adelante" quieres predecir con /un/ modelo?
- ¿Cuánto tiempo para la etiqueta usarás en las matrices de prueba?


Modelos de ensamble

Modelos de ensamble

Son aquellos en los que ocupamos *diversos* modelos para combinarlos y formar uno más fuerte. La diversidad es muy importante ya que permite que cada modelo vea un aspecto diferente de los mismos datos y baje la varianza. La diversidad puede venir de tener un mismo experimento diferentes datos de entrenamiento y pruebas, diferentes experimentos con el mismo algoritmo - modificando los hiper parámetros del modelo-, o bien, diferentes algoritmos.




Bagging



Tomamos diferentes muestras aleatorias de los datos CON reemplazo, suponemos que las diferencias en las muestras generadas con *bootstrap* llevarán a tener modelos diferentes, la predicción final se obtiene combinando el resultado de todos los modelos creados. Por otro lado, para seguir fomentando diversidad se seleccionan aleatoriamente las variables que forman parte de cada modelo *subspace sampling*. Ejemplo de este método de ensamble son los Random Forest.


Boosting



Otro método de ensamble, aquí se hacen muestras aleatorias de los datos SIN reemplazo formando modelos débiles secuenciales con cada muestra, por cada modelo generado se ocupan los errores del anterior para mejorar la salida. Ejemplo de este método de ensamble es AdaBoost.

La maldición de la dimensionalidad

Normalmente en un problema de minería de datos/ciencia de datos ocurre que hay muchas variables a tomar en cuenta para armar un modelo final que nos ayude a resolver el problema de negocio específico. Si bien, es posible incluir todas las variables en los modelos (aunque la mayoría de las veces no resulta tan adecuado por la maldición de la dimensionalidad), también es posible identificar las variables que más información nos dan antes de incluirlas en el modelo final, al igual que es posible generar nuevas variables derivadas de los datos originales que guardan la información más relevante al problema.



La primera opción ---identificar variables que más información aportan es conocida como *feature selection*, a la segunda opción que es generar nuevas variables derivadas de los datos originales se le conoce como *feature extraction*. Ambas opciones forman parte del proceso llamado *feature engineering* dentro de un proyecto de ciencia de datos.

Algunos métodos de *feature selection*: Árboles, Random Forests, Regresión lineal (con regularización Lasso).

Algunos métodos de *feature extraction*: PCA, SVD, Redes Neuronales Convolucionales (CNN).

The Machine Learning pipeline

