
INTRODUCCIÓN A CIENCIA DE DATOS

Fernanda Sobrino

2026

¿Qué es ciencia de datos?

¿Qué es ciencia de datos?

- ▶ Usar datos para responder preguntas y tomar decisiones
- ▶ No es (solo) programar: es formular la pregunta, conseguir y limpiar los datos, explorarlos, modelarlos y comunicar
- ▶ Combina **ciencia**, el método científico tanto en el diseño como en la implementación
- ▶ Con **datos** que sirven para probar hipótesis.
- ▶ Un producto de datos no es solamente un modelo — es un sistema complejo: **problema + modelo + tecnología**
- ▶ Con tres etapas de vida: entrenamiento (creación) → prueba (validación) → producción (uso)

¿Qué NO es ciencia de datos?

- ▶ No es una tecnología, ni una herramienta
- ▶ No es desarrollo de software
- ▶ No es Business Intelligence
- ▶ No es (únicamente) Big Data
- ▶ No es (únicamente) Inteligencia Artificial
- ▶ No es (únicamente) machine learning
- ▶ No es (únicamente) visualización, ni (únicamente) hacer modelos

... pero **utiliza todas** para entregar resultados

Mito 1: “ML/IA es la única manera de resolver problemas”

- ▶ Problemas determinísticos o con solución analítica pueden **no necesitar** un modelo de ML
- ▶ Desarrollar modelos de ML es costoso en tiempo y recursos
- ▶ Los modelos de ML dependen de datos abundantes y etiquetados
- ▶ Elegir *no* usar ML también es una decisión de ciencia de datos

Mito 2: “ML/IA es agnóstico a los datos”

- ▶ Los modelos absorben los **sesgos** presentes en los datos de entrenamiento — y los devuelven como predicciones sesgadas
- ▶ La calidad del resultado depende de la calidad de la entrada: *garbage in, garbage out*

Mito 3: “ML/IA es independiente del contexto”

- ▶ Interpretar resultados exige entender el problema **desde el origen de los datos**: cómo se generaron, su temporalidad, las interacciones entre variables
- ▶ Las variables del modelo se eligen con cuidado y **de la mano de expertos en el contexto**

Ciencia de datos y política pública

¿Por qué los gobiernos necesitan ciencia de datos?

- ▶ Los gobiernos deciden con datos (o deberían): focalización de programas, inspecciones, presupuesto, evaluación
- ▶ El riesgo nuevo no es la falta de análisis — es el **exceso de análisis automático sin verificación**
- ▶ Un reporte generado por IA se ve profesional y puede parecerlo aunque esté mal; alguien tiene que auditarlo para asegurarse que funcione
- ▶ Ese alguien: ustedes

Cómo se formula un problema: 8 pasos

- ▶ I Identificación del problema
- ▶ II Formulación (*scoping*)
- ▶ III Adquisición de datos
- ▶ IV Exploración
- ▶ V Formulación analítica
- ▶ VI Análisis / modelado
- ▶ VII Validación y prueba de campo
- ▶ VIII Acción

Fuente: *A Clinical Approach to Training Effective Data Scientists* (arxiv.org/pdf/1905.06875)

- ▶ **Esta será la parte más importante en políticas públicas:** un modelo perfecto de un problema mal formulado no sirve de nada

El scoping: 4 preguntas, en este orden

1. **¿Cuáles son las metas del proyecto?** El paso más importante. La mayoría de las veces se empieza con una definición vaga; hay que volverla **concreta, medible y optimizable** — iterando y priorizando trade-offs
2. **¿Qué acciones o intervenciones se van a mejorar?** Sin acciones concretas la solución no se implementa — y entonces **no es ciencia de datos**
3. **¿Qué datos tenemos y cuáles necesitamos?** ¡De los datos no se habla sino hasta el paso 3! Primero el problema; si empiezas por los datos acabas con productos “muertos”, no accionables
4. **¿Qué análisis necesitamos?** Y cómo lo vamos a validar — incluida una prueba en campo antes del despliegue

Caso: envenenamiento por plomo (I–IV)

- ▶ **Problema:** salud pública detecta tasas elevadas de plomo en sangre en infantes; hoy se actúa *después* de una prueba positiva. Meta: identificar hogares en riesgo **antes**
- ▶ **Scoping:** sesión con oficiales de salud, médicos, inspectores y científicos de datos. Intervención concreta: inspeccionar hogares de alto riesgo con menores de 12 meses, de forma **equitativa** entre comunidades
- ▶ **Datos:** pruebas de sangre, inspecciones, censo, programas de nutrición, geocodificación — entendiendo con los dueños cómo se generan
- ▶ **Exploración:** los valores faltantes revelan un error de ETL; una caída en pruebas de hace 17 años marca hasta dónde sirve la historia

Caso: envenenamiento por plomo (V–VIII)

- ▶ **Formulación analítica:** clasificación a nivel dirección, score mensual (el ciclo de planeación de inspecciones), cohorte de menores de 12 meses
- ▶ **La métrica viene del problema:** precisión en las 250 direcciones que el departamento puede inspeccionar al mes + representación de comunidades vulnerables
- ▶ **Modelado:** miles de configuraciones; gana un bosque aleatorio por precisión y equidad
- ▶ **Prueba de campo:** un año, 50 % de las direcciones inspeccionadas al azar — el modelo se confirma en el mundo real
- ▶ **Acción:** el departamento lo pone en producción y compromete recursos para mantenerlo. Sin este paso, todo lo anterior fue un ejercicio académico

Formular bien es la habilidad clave — también con IA

- ▶ En el ejemplo anterior el equipo decidió: la meta, la intervención, la unidad de análisis, la cohorte, la métrica, el criterio de equidad
- ▶ Un agente de IA puede escribir todo el código de ese proyecto — pero no puede hacer el scoping por ti
- ▶ La especificación que le das al agente son los pasos I–V; si están mal, el código funcionará... pero resolviendo el problema equivocado

Este curso

Este no es el típico curso de ML

Se deja en manos de los expertos...

- ▶ La teoría de los algoritmos y su construcción desde cero
- ▶ Las suposiciones matemáticas finas y la modificación de algoritmos

Aquí se prioriza...

- ▶ Leer, manipular y entender bases de datos
- ▶ Definir un proyecto de ciencia de datos y consumir modelos con criterio
- ▶ Usar las herramientas modernas (incluidos los agentes de IA) sin perder el control
- ▶ Desbloquear nuevas preguntas para resolver problemas reales

Objetivos de este curso

1. Manipular y limpiar datos con pandas (el 80 % del trabajo real)
2. Explorar datos y comunicarlos con visualizaciones
3. Entender y aplicar los modelos básicos de aprendizaje de máquina, supervisado y no supervisado
4. Elegir la **métrica correcta** para un problema de política pública y defender la elección
5. **Especificar y verificar** análisis hechos por agentes de IA: pedir bien y revisar con escepticismo

El elefante en el cuarto (el mundo)

- ▶ Los agentes de IA ya escriben la mayor parte del código de análisis de datos
- ▶ ¿Entonces por qué existe este curso? Porque el agente hace “*exactamente lo que le pides*”:
 - ▷ si no sabes pedir o no sabes bien lo que quieres, no te lo va a dar
 - ▷ si no sabes leer/interpretar lo que te regrese, no vas a notar cuando esté mal

**El agente pone el código;
tú pones el entendimiento.**

- ▶ Seguimos programando en Python: no puedes verificar código que no podrías haber escrito
- ▶ La IA se puede usar pero con transcripción obligatoria
- ▶ Practicamos la crítica: 4 sesiones de encontrar los errores de un análisis hecho por IA

RoadMap del curso

- ▶ Una sesión (larga) por semana; cada tarea se publica al cerrar su tema
- ▶ Semanas 1–4: Datos — pandas (2 clases), datos limpios (tidy), **verificación de análisis con IA**
- ▶ Semanas 5–6: EDA y visualización
- ▶ Semanas 7–9: Aprendizaje supervisado — teoría, sklearn, métricas — *Examen 1 (semana 7)*
- ▶ Semanas 10–11: Aprendizaje no supervisado (clustering) — *Examen 2 (semana 11)*
- ▶ Semana 12: Defensas finales y flujo de trabajo con agentes

Evaluación

Componente	Peso
Tareas (8, IA permitida con transcripción; se elimina la más baja)	25 %
Defensas orales (2 por estudiante, 10 min)	20 %
Exámenes en clase (2, escritos, sin computadora)	35 %
Ejercicios “Crítica a la IA” (4, cuentan 3)	15 %
Participación	5 %

► Temarios de exámenes en Exámenes/; rúbricas en Evaluacion/

Política de IA

- ▶ En **tareas**: cualquier LLM o agente permitido
 - ▷ Transcripción íntegra obligatoria — sin ella, la tarea no se califica
 - ▷ Toda tarea cierra con una sección de **Verificación**
- ▶ En **exámenes y defensas**: sin IA
 - ▷ Los exámenes no piden código: piden interpretar, diagnosticar, justificar
 - ▷ En la defensa explicas *tu* tarea y la modificas en vivo
- ▶ Eres responsable de todo lo que entregas: “lo escribió el agente” no es defensa

Defensas orales: qué esperar

- ▶ Dos veces en el semestre, 10 minutos
- ▶ Yo elijo cuál de tus tareas defiendes
- ▶ Explicas tu código, justificas decisiones, haces una modificación pequeña en vivo
- ▶ El mejor entrenamiento: antes de entregar, pregúntate “¿*puedo defender esto?*”

Herramientas

- ▶ Python 3 + Jupyter notebooks
- ▶ Puedes hacer todo en Google Colab si no quieres instalar nada
- ▶ `pandas`, `matplotlib/seaborn`, `scikit-learn`
- ▶ `git` (al final del curso)
- ▶ El LLM/agente de su elección — con las reglas del curso

Pregunta para pensar:

- ▶ ¿Qué análisis de datos has visto usarse (bien o mal) para justificar una decisión pública?

Recuerda:

- ▶ Descarga la carpeta completa del curso: github.com/FerSobrinio/intro-ciencia-datos (guía paso a paso: `tech-help/configuracion_entorno.md`)
- ▶ Leer la política de IA — la vamos a discutir
- ▶ Tener funcionando python en algún lado para poder seguir la clase (Colab cuenta — misma guía)