
ANÁLISIS EXPLORATORIO

Fernanda Sobrino

2026

¿Qué es el análisis exploratorio (EDA)?

Mirar los datos antes de modelar

“Loosely speaking, any method of looking at data that does not include formal statistical modeling and inference falls under the term exploratory data analysis”
— Howard Seltman

- ▶ Origen: Mosteller y Tukey (1977), *Data analysis and regression*
- ▶ La idea: mira los datos para ver lo que parecen decir, antes de imponerles un modelo
- ▶ Objetivos concretos:
 - ▷ entender la estructura del conjunto de datos y las variables importantes
 - ▷ detectar valores atípicos, anomalías y datos faltantes
 - ▷ comprobar los supuestos que un modelo va a dar por buenos


Dos enfoques

Enfoque clásico	EDA
Problema → Datos → Modelo → Análisis → Conclusiones	Problema → Datos → Análisis → Modelo → Conclusiones
Impone el modelo	Los datos sugieren el modelo
Técnicas cuantitativas: pruebas de hipótesis, ANOVA, mínimos cuadrados	Técnicas gráficas: histogramas, scatter plots, boxplots, residual plots
Hace supuestos	Sin supuestos previos
Riguroso	Subjetivo e interpretativo

- No son rivales: EDA es lo que haces antes para que el modelo clásico tenga sentido

El cuarteto de Anscombe

Cuarteto de Anscombe: mismas estadísticas, datos distintos



El cuarteto de Anscombe: ¿qué estamos viendo?

- ▶ Cuatro conjuntos con la misma media, la misma varianza, la misma recta de regresión y la misma correlación ($r = 0.82$)
- ▶ Y cuatro historias distintas: lineal, curva, un outlier que arrastra la recta, y una x casi constante
- ▶ Moraleja: es fácil falsear una estadística de resumen; es mucho más difícil falsear una distribución

El mapa del EDA

Pregunta	Cómo se contesta	Qué está buscando
¿Qué tengo?	<code>shape</code> , <code>info</code> , <code>dtypes</code>	¿coincide con lo que dice la fuente?
¿Cuál es la unidad?	¿la llave es única?	qué es un renglón
¿Cómo se ve una variable?	histograma + <code>describe</code>	forma, sesgo, topes de codificación
¿Y una categórica?	<code>value_counts</code>	categorías repetidas, mal escritas, vacías
¿Qué falta?	<code>isnull().mean()</code> por columna	patrón, no solo cantidad
¿Hay imposibles?	<code>min</code> , <code>max</code> , centinelas	-99, negativos, fechas del futuro
¿Se mueven juntas?	scatter, correlación	relaciones (y sus trampas)

- El orden importa: **primero mirar, después resumir**. Un `describe()` sin gráfica es Anscombe esperando a pasar

La distribución de una variable

Una variable sola: conteos e histogramas



Categóricas — el conteo por categoría es el punto de partida

- ▶ ¿El orden es el esperado? Las **ordinales** **hay que declararlas** como tales, o pandas las ordena alfabéticamente
- ▶ Con muchísimas categorías la gráfica deja de comunicar: agrupa la cola larga en otros
- ▶ **Ojo con promediar categorías**: si codificas [1, 2, 3] y sacas promedio, puedes obtener 2 aunque nadie haya escogido 2

Continuas — el histograma parte el rango en intervalos iguales y cuenta

- ▶ Lo que buscamos es **señal**: un pico, una tendencia central
- ▶ Una distribución uniforme (todas las cajas igual de altas) es señal de que *no hay señal*
- ▶ Error común: creer que los datos continuos “deberían” seguir una normal. En la naturaleza casi ninguna variable lo hace

El parámetro cambia la historia



- ▶ Los **mismos datos** con bins por defecto y con bins=50: con 50 cajas aparece la estructura fina; con pocas se suaviza y se pierde
- ▶ La barra en 50 no es ruido: es un **tope de codificación** (todo valor ≥ 50 se registró como 50), y solo se ve con suficientes cajas
- ▶ Igual con la **densidad** (kde): ancho de banda grande $\rightarrow$ curva suave; chico $\rightarrow$ ruido puro
- ▶ Regla: prueba **dos anchos** antes de concluir algo sobre la forma, y reporta histograma y densidad juntos

Sesgo y transformaciones

- ▶ Sesgo a la derecha: cola larga a la derecha (ingreso, empleo, población, precios). A la izquierda: cola larga a la izquierda (edad de jubilación, calificaciones con techo)
- ▶ Una variable muy sesgada comprime la masa central en un pedacito de la gráfica: **no se puede inspeccionar visualmente**
- ▶ Antes de “arreglarla”, **investiga la cola**: la cola de `all.emp` son Cook (Chicago), Los Ángeles y los cinco condados de Nueva York — el 20 % de condados más poblados concentra el 85.9 % del empleo
- ▶ Si la cola tiene explicación sustantiva, no es un problema: **es el fenómeno**
- ▶ Muchos modelos suponen normalidad. Sesgo a la derecha → **logaritmo** o **raíz**; a la izquierda → cuadrado
- ▶ El **gráfico QQ** dice si sirvió: tus cuantiles contra los de una normal teórica — entre más pegados a la recta, mejor
- ▶ No transformes a ciegas: ganas supuestos y **pierdes interpretabilidad**

Centralidad, dispersión y valores extremos

Media vs. mediana


- ▶ **Media:** sensible a la cola. En una variable sesgada, la media se va detrás de los valores extremos
- ▶ **Mediana:** el valor de en medio; no le importa qué tan lejos esté la cola
- ▶ **Moda:** la única que tiene sentido para datos ordinales o categóricos
- ▶ Si comparas conteo, suma, media y mediana por región vas a ver **cuatro rankings distintos** de las mismas regiones
- ▶ Regla práctica: si media y mediana difieren mucho, la variable es sesgada y **la mediana es el resumen honesto**
- ▶ En política pública esto importa: “el ingreso promedio del municipio” y “el ingreso del habitante típico” no son lo mismo

Dispersión: qué tan lejos están del centro

Medida	Interpretación	Cuidado
Varianza	Grado de dispersión; alto = datos lejos del promedio	Está en unidades al cuadrado
Desviación estándar	Raíz de la varianza; en las mismas unidades que el promedio	Igual de sensible a outliers que la media
Rango intercuartil (IQR)	Ancho del 50 % central	Robusto: es el que usa el boxplot
Coeficiente de variación	sd / media, en % — permite comparar variables con unidades distintas	Un CV > 100 % dice que el promedio casi no informa

- ▶ Para pensar: dos poblaciones con la misma estatura promedio pero varianzas muy distintas, ¿son la misma población?
- ▶ Si un intervalo de confianza contiene valores positivos y negativos, **no puedes concluir que el efecto es positivo**

Valores extremos: cómo se ven y qué hacer



- ▶ El boxplot marca como atípico lo que cae fuera de los bigotes ($1.5 \times \text{IQR}$)
- ▶ En un histograma se ven poniendo un **límite al eje y**: son tan pocos que no se distinguen del cero
- ▶ Diamantes con ancho 0 mm o 58 mm no son outliers estadísticos: son **errores de captura**

Tres opciones, ninguna gratis: **tirarlos** (pierdes información y sesgas si el extremo es real), **convertirlos en faltantes** (conservas el renglón, marcas la duda), **winsorizar** (recortar al percentil 1 y 99).

- ▶ ¿Cómo decidir? **Pregúntale a quien construyó la base** por qué esos valores son raros
- ▶ En datos reales *toda* columna tiene basura: si tiras cada renglón con un valor raro, te quedas sin base

Valores faltantes

Un faltante no siempre se llama NaN

- ▶ Revisa **siempre el diccionario de datos**: no es lo mismo un dato faltante, un “No aplica” y un cero
- ▶ Los códigos centinela (-99, 999, -1, "", "N/A") entran como números y **contaminan promedios sin avisar**
- ▶ Los infinitos (`np.inf`) son otro caso: no son nulos, y `isnull()` no los ve
- ▶ pandas usa dos representaciones: `np.nan` (float, rápido, de NumPy) y `None` (objeto de Python, lento)
- ▶ Detectar es fácil (`isnull`, `notnull`, `dropna`, `fillna`); lo importante es el **patrón**:
 - ▷ por columna: ¿hay una variable que casi nadie contestó?
 - ▷ por renglón: ¿hay un grupo de observaciones que no contestó casi nada?

El mecanismo importa: MCAR, MAR, MNAR

Rubin (1976). El tratamiento correcto depende de **por qué** falta el dato:

- ▶ **MCAR** (*completely at random*): la falta no se correlaciona con nada observado. La no respuesta a “ingreso” es independiente de escolaridad o pobreza. **No sesga**
- ▶ **MAR** (*at random*): la falta depende de variables **observadas**. No responden ingreso los de menor escolaridad — y la escolaridad sí la tienes. **Sesga si no lo tratas**
- ▶ **MNAR** (*not at random*): la falta depende del valor **no observado**. No responden ingreso justamente los de ingreso alto. **El caso feo**: no se puede diagnosticar con los datos, requiere conocimiento del tema
- ▶ Se diagnostica comparando a los que sí contestaron contra los que no, en las variables que sí tienes. Eso distingue MCAR de MAR — **nunca MNAR**

Por qué “borrar los NaN” sesga

► `dropna()` es la primera línea que escribe cualquier agente. Dos problemas:

1. Te quedas sin datos. Con 100 columnas y ~12 % de faltantes por columna, casi **ningún** renglón está completo. Hay un intercambio entre renglones completos y variables retenidas: a veces conviene tirar la columna, no el renglón

2. Los que quedan no son como los que se fueron. Si el mecanismo es MAR, el análisis de casos completos describe a **quienes sí respondieron**, no a la población

► Además, `groupby().mean()` descarta faltantes en silencio: “el promedio de todos” en realidad es “el promedio de los que tenían dato”

► Mínimo exigible: reportar cuántos renglones se perdieron y **comparar los que se van contra los que se quedan**

Tratamiento de los faltantes

Opción	Descripción	MCAR	MAR
<i>Listwise deletion</i>	Eliminar el renglón con cualquier faltante (casos completos)	x	
<i>Drop variable</i>	Eliminar la variable — si los faltantes se concentran en una columna	x	x
Media / mediana	Sustituir por el centro. Media si es simétrica, mediana si es sesgada	x	
Moda	Para variables discretas	x	
Basada en modelo	Predecir el faltante con kNN, árboles, <i>random forest</i>	x	x
Imputación múltiple	Imputar varias veces y promediar, para no subestimar la incertidumbre	x	x

- ▶ Imputar la media **preserva la media y destroza la forma**: pico artificial en el centro, varianza subestimada
- ▶ **Verifícalo**: grafica la densidad original contra la imputada. Si la forma cambió, la imputación inventó estructura
- ▶ Regla de higiene que veremos en modelos: **imputa después del split, con estadísticas de train**



Correlaciones y cierre

La nube de puntos y el coeficiente de Pearson

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

- ▶ Mide fuerza y dirección de una relación **lineal**, entre -1 y 1
- ▶ La nube de puntos va **antes** que el coeficiente: el número resume, la nube explica
- ▶ Con dos variables: scatter con recta ajustada, y las marginales al lado para no perder de vista cada distribución
- ▶ Con un grupo de variables: matriz de correlación o `clustermap` para agrupar las que se mueven juntas — pero **léela como mapa, no como conclusión**
- ▶ Con dos categóricas: una tabla cruzada de frecuencias, vista como mapa de calor
- ▶ Y siempre: ¿la relación se mantiene **dentro** de cada subgrupo, o solo entre grupos?

Las trampas de la correlación



1. **Correlación $\neq$ causalidad**, y con suficientes variables siempre encuentras una correlación alta por azar
2. Pearson **solo ve líneas**: una U perfecta tiene correlación ≈ 0 . Si la nube no es una “línea difusa”, sigue investigando
3. Un solo outlier puede crear o destruir una correlación (Anscombe III y IV)
4. Fíjate hasta en el eje: en la gráfica de piratas el eje x **ni siquiera está ordenado**

La regla del curso

Nunca modifiques la base original.

- ▶ Puedes **agregar** columnas (`y_winsor`, `ba_imputada`, `es_outlier`), nunca borrar renglones, columnas o celdas del archivo fuente
- ▶ Todo filtro y toda imputación vive en el código, no en el archivo: así el análisis es reproducible y auditable
- ▶ Documenta cada decisión: cuántos renglones quitaste, con qué criterio y qué pasa si no los quitas
- ▶ Y la pregunta de cierre del EDA: **¿la conclusión sobrevive si tomo la otra decisión razonable?**

AI notebook

Lo que vamos a hacer en EDA.ipynb

1. **matplotlib y seaborn** en breve, sobre series económicas de EE.UU.
 2. **Distribuciones discretas**: `countplot`, categorías ordinales, colas largas de categorías
 3. **Distribuciones continuas**: histogramas, bins, densidad y ancho de banda; variables asimétricas, log, raíz y gráfico QQ
 4. **Outliers**: `boxplot`, límites del eje, y las tres opciones (tirar, NaN, winsorizar)
 5. **Faltantes**: detección, patrón por columna y renglón, diagnóstico MCAR/MAR, dropna vs. imputación (media, mediana, kNN) y qué le hace cada una a la distribución
 6. **Series de tiempo y correlaciones**: `regplot`, `jointplot`, `lmpplot` por grupo, `pairplot`, mapas de calor y datos de mayor dimensionalidad
- Los **ejercicios en clase** están marcados en el notebook — se hacen ahí, en el momento

Qué verificar cuando el agente hace esto

1. **¿Graficó, o solo reportó estadísticas de resumen?** Un `describe()` sin histograma es Anscombe esperando a pasar. Pide la distribución de toda variable clave
2. **¿Usó media donde la variable es sesgada?** Compara media y mediana; si difieren mucho y el reporte dice “promedio”, el número está inflado por la cola
3. **¿Cuántos renglones sobrevivieron?** Exige `len(df)` antes y después de cada `dropna()` o filtro, y la comparación entre quienes se fueron y quienes se quedaron
4. **¿Justificó el mecanismo de faltantes?** Un `dropna()` o un `fillna(mean)` sin diagnóstico MCAR/MAR es una decisión escondida, no una limpieza

Qué verificar cuando el agente hace esto (cont.)

5. **¿Revisó códigos centinela y valores imposibles?** -99, ceros donde no puede haberlos, topes de codificación: `min()`, `max()` y `value_counts()` de los extremos
6. **¿Modificó la base original?** Cualquier archivo de datos que cambió de tamaño es una bandera roja: la limpieza va en el código
7. **¿La correlación que reporta es lineal y tiene sentido sustantivo?** Pídele el scatter, no el número