

---

# ANÁLISIS EXPLORATORIO

---

Fernanda Sobrino

2026

**¿Qué es el análisis exploratorio (EDA)?**

---

# Mirar los datos antes de modelar

---

*“Loosely speaking, any method of looking at data that does not include formal statistical modeling and inference falls under the term exploratory data analysis”*  
— Howard Seltman

- ▶ Origen: Mosteller y Tukey (1977), *Data analysis and regression*
- ▶ La idea: mira los datos para ver lo que parecen decir, antes de imponerles un modelo
- ▶ Objetivos concretos:
  - ▷ entender la estructura del conjunto de datos y las variables importantes
  - ▷ detectar valores atípicos, anomalías y datos faltantes
  - ▷ comprobar los supuestos que un modelo va a dar por buenos

# Dos enfoques


---

| Enfoque clásico                                                        | EDA                                                                     |
|------------------------------------------------------------------------|-------------------------------------------------------------------------|
| Problema → Datos → Modelo → Análisis → Conclusiones                    | Problema → Datos → Análisis → Modelo → Conclusiones                     |
| Impone el modelo                                                       | Los datos sugieren el modelo                                            |
| Técnicas cuantitativas: pruebas de hipótesis, ANOVA, mínimos cuadrados | Técnicas gráficas: histogramas, scatter plots, boxplots, residual plots |
| Hace supuestos                                                         | Sin supuestos previos                                                   |
| Riguroso                                                               | Subjetivo e interpretativo                                              |

- No son rivales: EDA es lo que haces antes para que el modelo clásico tenga sentido

# El cuarteto de Anscombe

Cuarteto de Anscombe: mismas estadísticas, datos distintos



# El cuarteto de Anscombe: ¿qué estamos viendo?

---

- ▶ Cuatro conjuntos con la misma media, la misma varianza, la misma recta de regresión y la misma correlación ( $r = 0.82$ )
- ▶ Y cuatro historias distintas: lineal, curva, un outlier que arrastra la recta, y una  $x$  casi constante
- ▶ Moraleja: es fácil falsear una estadística de resumen; es mucho más difícil falsear una distribución

# El mapa del EDA

| Pregunta                  | Cómo se contesta                         | Qué está buscando                          |
|---------------------------|------------------------------------------|--------------------------------------------|
| ¿Qué tengo?               | <code>shape, info, dtypes</code>         | ¿coincide con lo que dice la fuente?       |
| ¿Cuál es la unidad?       | ¿la llave es única?                      | qué es un renglón                          |
| ¿Cómo se ve una variable? | <code>histograma + describe</code>       | forma, sesgo, topes de codificación        |
| ¿Y una categórica?        | <code>value_counts</code>                | categorías repetidas, mal escritas, vacías |
| ¿Qué falta?               | <code>isnull().mean()</code> por columna | patrón, no solo cantidad                   |
| ¿Hay imposibles?          | <code>min, max, centinelas</code>        | -99, negativos, fechas del futuro          |
| ¿Se mueven juntas?        | <code>scatter, correlación</code>        | relaciones (y sus trampas)                 |

► El orden si importa: primero mirar, después resumir.

# La distribución de una variable

---

# Una variable sola: conteos e histogramas

---

**Catagóricas** — primero contar cuantas cosas hay por categoría

- ▶ ¿El orden es el esperado? Las **ordinales** hay que **declararlas** como tales, o pandas las ordena alfabéticamente
- ▶ Si tienes muchas categorías la gráfica no va a servir: agrupa la cola larga en otros
- ▶ Ojo con promediar categorías: si codificas [1, 2, 3] y sacas promedio, puedes obtener 2 aunque nadie haya escogido 2

# Una variable sola: conteos e histogramas



---

**Continuas** — un histograma es el primer paso

- ▶ Lo que buscamos es que la distribución de vea como esperamos que sea
- ▶ Si tiene alguna clase de señal: picos, tendencias centrales, colas pesadas
- ▶ Ojo: los datos continuos no tienen que distribuirse como una normal
- ▶ En la naturaleza casi ninguna variable se va a ver así

# El parámetro cambia la historia

---



► Los mismos datos con bins por defecto y con bins=50

# Centralidad, dispersión y valores extremos

---

# Media vs. mediana

---

- ▶ **Media:** sensible a valores extremos.
- ▶ **Mediana:** el valor de en medio; no le importan los extremos
- ▶ **Moda:** la única que tiene sentido para datos ordinales o categóricos
- ▶ Regla práctica: si media y mediana difieren mucho, la variable es sesgada


# Dispersión: qué tan lejos están del centro

---

| Medida                   | Interpretación                                                          | Cuidado                                              |
|--------------------------|-------------------------------------------------------------------------|------------------------------------------------------|
| Varianza                 | Grado de dispersión; alto = datos lejos del promedio                    | Está en unidades al cuadrado                         |
| Desviación estándar      | Raíz de la varianza; en las mismas unidades que el promedio             | Igual de sensible a outliers que la media            |
| Rango intercuartil (IQR) | Ancho del 50 % central                                                  | Robusto: es el que usa el boxplot                    |
| Coeficiente de variación | $sd / media$ , en % — permite comparar variables con unidades distintas | Un $CV > 100\%$ dice que el promedio casi no informa |

# Valores extremos: cómo se ven

---



- ▶ El boxplot marca como atípico lo que cae fuera de los bigotes ( $1.5 \times \text{IQR}$ )
- ▶ En un histograma se ven poniendo un **límite al eje y**: son tan pocos que no se distinguen del cero
- ▶ Diamantes con ancho 0 mm o 58 mm no son outliers estadísticos: son **errores de captura**

# Valores extremos: qué hacer con ellos

---

Tres opciones, ninguna gratis:

- ▶ **Tirarlos** — pierdes información y sesgas si el extremo es real
  - ▶ **Convertirlos en faltantes** — conservas el renglón, marcas la duda
  - ▶ **Winsorizar** — recortar al percentil 1 y 99
- 
- ▶ ¿Cómo decidir? **Pregúntale a quien construyó la base** por qué esos valores son raros
  - ▶ En datos reales *toda* columna tiene basura: si tiras cada renglón con un valor raro, te quedas sin base

# Valores faltantes

---

# Un faltante no siempre se llama NaN

---

- ▶ Revisa **siempre el diccionario de datos**: no es lo mismo un dato faltante, un “No aplica” y un cero
- ▶ Los códigos centinela (-99, 999, -1, "", "N/A") entran como números y **contaminan promedios sin avisar**
- ▶ Los infinitos (`np.inf`) son otro caso: no son nulos, y `isnull()` no los ve
- ▶ pandas usa dos representaciones: `np.nan` (float, rápido, de NumPy) y `None` (objeto de Python, lento)
- ▶ Detectar es fácil (`isnull`, `notnull`, `dropna`, `fillna`); lo importante es el **patrón**:
  - ▷ por columna: ¿hay una variable que casi nadie contestó?
  - ▷ por renglón: ¿hay un grupo de observaciones que no contestó casi nada?

# El mecanismo importa: MCAR, MAR, MNAR

---

Rubin (1976). El tratamiento correcto depende de **por qué** falta el dato:

- ▶ **MCAR** (*completely at random*): la falta no se correlaciona con nada observado. La no respuesta a “ingreso” es independiente de escolaridad o pobreza. **No sesga**
- ▶ **MAR** (*at random*): la falta depende de variables **observadas**. No responden ingreso los de menor escolaridad — y la escolaridad sí la tienes. **Sesga si no lo tratas**
- ▶ **MNAR** (*not at random*): la falta depende del valor **no observado**. No responden ingreso justamente los de ingreso alto. **El caso feo**: no se puede diagnosticar con los datos, requiere conocimiento del tema
- ▶ Se diagnostica comparando a los que sí contestaron contra los que no, en las variables que sí tienes. Eso distingue MCAR de MAR — **nunca MNAR**

# Por qué “borrar los NaN” sesga

---

► `dropna()` es la primera línea que escribe cualquier agente. Dos problemas:

**1. Te quedas sin datos.** Con 100 columnas y ~12 % de faltantes por columna, casi **ningún** renglón está completo. Hay un intercambio entre renglones completos y variables retenidas: a veces conviene tirar la columna, no el renglón

**2. Los que quedan no son como los que se fueron.** Si el mecanismo es MAR, el análisis de casos completos describe a **quienes sí respondieron**, no a la población

► Además, `groupby().mean()` descarta faltantes en silencio: “el promedio de todos” en realidad es “el promedio de los que tenían dato”

► Mínimo exigible: reportar cuántos renglones se perdieron y **comparar los que se van contra los que se quedan**

# Tratamiento de los faltantes

| Opción                   | Descripción                                                                  | MCAR | MAR |
|--------------------------|------------------------------------------------------------------------------|------|-----|
| <i>Listwise deletion</i> | Eliminar el renglón con cualquier faltante (casos completos)                 | x    |     |
| <i>Drop variable</i>     | Eliminar la variable — si los faltantes se concentran en una columna         | x    | x   |
| Media / mediana          | Sustituir por el centro. Media si es simétrica, <b>mediana si es sesgada</b> | x    |     |
| Moda                     | Para variables discretas                                                     | x    |     |
| Basada en modelo         | Predecir el faltante con kNN, árboles, <i>random forest</i>                  | x    | x   |
| Imputación múltiple      | Imputar varias veces y promediar, para no subestimar la incertidumbre        | x    | x   |

- ▶ Imputar la media **preserva la media y destroza la forma**: pico artificial en el centro, varianza subestimada
- ▶ **Verifícalo**: grafica la densidad original contra la imputada. Si la forma cambió, la imputación inventó estructura
- ▶ Regla de higiene que veremos en modelos: **imputa después del split, con estadísticas de train**

# Correlaciones y cierre

---



# La nube de puntos y el coeficiente de Pearson

---

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

- ▶ Mide fuerza y dirección de una relación **lineal**, entre -1 y 1
- ▶ La nube de puntos va **antes** que el coeficiente: el número resume, la nube explica
- ▶ Con dos variables: scatter con recta ajustada, y las marginales al lado para no perder de vista cada distribución
- ▶ Con un grupo de variables: matriz de correlación o `clustermap` para agrupar las que se mueven juntas — pero **léela como mapa, no como conclusión**
- ▶ Con dos categóricas: una tabla cruzada de frecuencias, vista como mapa de calor
- ▶ Y siempre: ¿la relación se mantiene **dentro** de cada subgrupo, o solo entre grupos?

# Las trampas de la correlación



1. **Correlación  $\neq$  causalidad**, y con suficientes variables siempre encuentras una correlación alta por azar
2. Pearson **solo ve líneas**: una U perfecta tiene correlación  $\approx 0$ . Si la nube no es una “línea difusa”, sigue investigando
3. Un solo outlier puede crear o destruir una correlación (Anscombe III y IV)
4. Fíjate hasta en el eje: en la gráfica de piratas el eje x **ni siquiera está ordenado**

# La regla del curso

---

## Nunca modifiques la base original.

- ▶ Puedes **agregar** columnas (`y_winsor`, `ba_imputada`, `es_outlier`), nunca borrar renglones, columnas o celdas del archivo fuente
- ▶ Todo filtro y toda imputación vive en el código, no en el archivo: así el análisis es reproducible y auditable
- ▶ Documenta cada decisión: cuántos renglones quitaste, con qué criterio y qué pasa si no los quitas
- ▶ Y la pregunta de cierre del EDA: **¿la conclusión sobrevive si tomo la otra decisión razonable?**

# AI notebook

---

# Lo que vamos a hacer en EDA.ipynb

---

1. **matplotlib y seaborn** en breve, sobre series económicas de EE.UU.
  2. **Distribuciones discretas:** countplot, categorías ordinales, colas largas de categorías
  3. **Distribuciones continuas:** histogramas, bins, densidad y ancho de banda; variables asimétricas, log, raíz y gráfico QQ
  4. **Outliers:** boxplot, límites del eje, y las tres opciones (tirar, NaN, winsorizar)
  5. **Faltantes:** detección, patrón por columna y renglón, diagnóstico MCAR/MAR, dropna vs. imputación (media, mediana, kNN) y qué le hace cada una a la distribución
  6. **Series de tiempo y correlaciones:** regplot, jointplot, lmpplot por grupo, pairplot, mapas de calor y datos de mayor dimensionalidad
- Los **ejercicios en clase** están marcados en el notebook — se hacen ahí, en el momento

## Qué verificar cuando el agente hace esto

---

1. **¿Graficó, o solo reportó estadísticas de resumen?** Un `describe()` sin histograma es Anscombe esperando a pasar. Pide la distribución de toda variable clave
2. **¿Usó media donde la variable es sesgada?** Compara media y mediana; si difieren mucho y el reporte dice “promedio”, el número está inflado por la cola
3. **¿Cuántos renglones sobrevivieron?** Exige `len(df)` antes y después de cada `dropna()` o filtro, y la comparación entre quienes se fueron y quienes se quedaron
4. **¿Justificó el mecanismo de faltantes?** Un `dropna()` o un `fillna(mean)` sin diagnóstico MCAR/MAR es una decisión escondida, no una limpieza

## Qué verificar cuando el agente hace esto (cont.)

---

5. **¿Revisó códigos centinela y valores imposibles?** -99, ceros donde no puede haberlos, topes de codificación: `min()`, `max()` y `value_counts()` de los extremos
6. **¿Modificó la base original?** Cualquier archivo de datos que cambió de tamaño es una bandera roja: la limpieza va en el código
7. **¿La correlación que reporta es lineal y tiene sentido sustantivo?** Pídele el scatter, no el número