
ANÁLISIS EXPLORATORIO

Fernanda Sobrino

2026

¿Qué es el análisis exploratorio (EDA)?

Mirar los datos antes de modelar

“Loosely speaking, any method of looking at data that does not include formal statistical modeling and inference falls under the term exploratory data analysis”
— Howard Seltman

- ▶ Origen: Mosteller y Tukey (1977), *Data analysis and regression*
- ▶ La idea: mira los datos para ver lo que parecen decir, antes de imponerles un modelo
- ▶ Objetivos concretos:
 - ▷ entender la estructura del conjunto de datos y las variables importantes
 - ▷ detectar valores atípicos, anomalías y datos faltantes
 - ▷ comprobar los supuestos que un modelo va a dar por buenos


Dos enfoques

Enfoque clásico	EDA
Problema → Datos → Modelo → Análisis → Conclusiones	Problema → Datos → Análisis → Modelo → Conclusiones
Impone el modelo	Los datos sugieren el modelo
Técnicas cuantitativas: pruebas de hipótesis, ANOVA, mínimos cuadrados	Técnicas gráficas: histogramas, scatter plots, boxplots, residual plots
Hace supuestos	Sin supuestos previos
Riguroso	Subjetivo e interpretativo

- No son rivales: EDA es lo que haces antes para que el modelo clásico tenga sentido

El cuarteto de Anscombe

Cuarteto de Anscombe: mismas estadísticas, datos distintos



El cuarteto de Anscombe: ¿qué estamos viendo?

- ▶ Cuatro conjuntos con la misma media, la misma varianza, la misma recta de regresión y la misma correlación ($r = 0.82$)
- ▶ Y cuatro historias distintas: lineal, curva, un outlier que arrastra la recta, y una x casi constante
- ▶ Moraleja: es fácil falsear una estadística de resumen; es mucho más difícil falsear una distribución

El mapa del EDA

Pregunta	Cómo se contesta	Qué está buscando
¿Qué tengo?	<code>shape</code> , <code>info</code> , <code>dtypes</code>	¿coincide con lo que dice la fuente?
¿Cuál es la unidad?	¿la llave es única?	qué es un renglón
¿Cómo se ve una variable?	<code>histograma</code> + <code>describe</code>	forma, sesgo, topes de codificación
¿Y una categórica?	<code>value_counts</code>	categorías repetidas, mal escritas, vacías
¿Qué falta?	<code>isnull().mean()</code> por columna	patrón, no solo cantidad
¿Hay imposibles?	<code>min</code> , <code>max</code> , centinelas	-99, negativos, fechas del futuro
¿Se mueven juntas?	<code>scatter</code> , correlación	relaciones (y sus trampas)

► El orden si importa: primero mirar, después resumir.

La distribución de una variable

Una variable sola: conteos e histogramas

Catagóricas — primero contar cuantas cosas hay por categoría



- ▶ ¿El orden es el esperado? Las **ordinales** hay que **declararlas** como tales, o pandas las ordena alfabéticamente
- ▶ Si tienes muchas categorías la gráfica no va a servir: agrupa la cola larga en otros
- ▶ Ojo con promediar categorías: si codificas [1, 2, 3] y sacas promedio, puedes obtener 2 aunque nadie haya escogido 2

Una variable sola: conteos e histogramas

Continuas — un histograma es el primer paso

- ▶ Lo que buscamos es que la distribución de vea como esperamos que sea
- ▶ Si tiene alguna clase de señal: picos, tendencias centrales, colas pesadas
- ▶ Ojo: los datos continuos no tienen que distribuirse como una normal
- ▶ En la naturaleza casi ninguna variable se va a ver así

El parámetro cambia la historia



► Los mismos datos con bins por defecto y con bins=50

Centralidad, dispersión y valores extremos


Media vs. mediana

- ▶ **Media:** sensible a valores extremos.
- ▶ **Mediana:** el valor de en medio; no le importan los extremos
- ▶ **Moda:** la única que tiene sentido para datos ordinales o categóricos
- ▶ Regla práctica: si media y mediana difieren mucho, la variable es sesgada

Dispersión: qué tan lejos están del centro

Medida	Interpretación	Cuidado
Varianza	Grado de dispersión; alto = datos lejos del promedio	Está en unidades al cuadrado
Desviación estándar	Raíz de la varianza; en las mismas unidades que el promedio	Igual de sensible a outliers que la media
Rango intercuartil (IQR)	Ancho del 50 % central	Robusto: es el que usa el boxplot
Coeficiente de variación	$sd / media$, en % — permite comparar variables con unidades distintas	Un $CV > 100\%$ dice que el promedio casi no informa

Valores extremos: cómo se ven



- ▶ El boxplot marca como atípico lo que cae fuera de los bigotes ($1.5 \times \text{IQR}$)
- ▶ En un histograma se ven poniendo un **límite al eje y**: son tan pocos que no se distinguen del cero

Valores extremos: qué hacer con ellos

Tres opciones, todas tienen consecuencias:

- ▶ **Tirarlos** — pierdes información y sesgas si el extremo es real
- ▶ **Convertirlos en faltantes** — conservas el renglón, marcas la duda
- ▶ **Winsorizar** — recortar al percentil 1 y 99

- ▶ ¿Cómo decidir? **Pregúntale a quien construyó la base** por qué esos valores son raros
- ▶ En datos reales *toda* columna tiene basura: si tiras cada renglón con un valor raro, te quedas sin base

Valores faltantes

Un faltante no siempre va a ser un NaN

- ▶ Revisa siempre el diccionario de datos: no es lo mismo un dato faltante, un “No aplica” y un cero
- ▶ Los códigos centinela (-99, 999, -1, "", "N/A") entran como números y van a contaminar el análisis si no te das cuenta
- ▶ Los infinitos (`np.inf`) son otro caso: no son nulos, y `isnull()` no los ve
- ▶ pandas usa dos representaciones: `np.nan` (float, rápido, de NumPy) y `None` (objeto de Python, lento)
- ▶ Detectar es fácil (`isnull`, `notnull`, `dropna`, `fillna`); lo importante es el patrón:
 - ▷ por columna: ¿hay una variable que casi nadie contestó?
 - ▷ por renglón: ¿hay un grupo de observaciones que no contestó casi nada?

El mecanismo importa: MCAR, MAR, MNAR

Rubin (1976). El tratamiento correcto depende de **por qué** falta el dato:

- ▶ **MCAR** (*completely at random*): la falta no se correlaciona con nada observado. La no respuesta a “ingreso” es independiente de escolaridad o pobreza. No sesga
- ▶ **MAR** (*at random*): la falta depende de variables observadas. No responden ingreso los de menor escolaridad — y la escolaridad sí la tienes. Sesga si no lo tratas
- ▶ **MNAR** (*not at random*): la falta depende del valor no observado. No responden ingreso justamente los de ingreso alto. No se puede diagnosticar con los datos, requiere conocimiento del tema
- ▶ Se diagnostica comparando a los que sí contestaron contra los que no, en las variables que sí tienes. Eso distingue MCAR de MAR pero nunca MNAR

Por qué no hay que borrar los NaN

- ▶ `dropna()` puede parecer lo primero que hay que hacer pero hay dos problemas con esto:

1. Te quedas sin datos. Con 100 columnas y ~12 % de faltantes por columna, casi ningún renglón está completo. Hay un intercambio entre renglones completos y variables retenidas: a veces conviene tirar la columna, no el renglón

2. Los que quedan no son como los que se fueron. Si el mecanismo es MAR, el análisis de casos completos describe a quienes sí respondieron, no a la población

- ▶ Además, `groupby().mean()` descarta faltantes en silencio: “el promedio de todos” en realidad es “el promedio de los que tenían dato”

Tratamiento de los faltantes

Opción	Descripción	MCAR	MAR
<i>Listwise deletion</i>	Eliminar el renglón con cualquier faltante (casos completos)	x	
<i>Drop variable</i>	Eliminar la variable — si los faltantes se concentran en una columna	x	x
Media / mediana	Sustituir por el centro. Media si es simétrica, mediana si es sesgada	x	
Moda	Para variables discretas	x	
Basada en modelo	Predecir el faltante con kNN, árboles, random forest	x	x
Imputación múltiple	Imputar varias veces y promediar, para no subestimar la incertidumbre	x	x



Correlaciones

La nube de puntos y el coeficiente de Pearson

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

- ▶ Mide fuerza y dirección de una relación lineal, entre -1 y 1
- ▶ La nube de puntos va antes que el coeficiente: el número resume, la nube explica
- ▶ Con dos variables: scatter con recta ajustada, y las marginales al lado para no perder de vista cada distribución
- ▶ Con un grupo de variables: matriz de correlación o `clustermap` para agrupar las que se mueven juntas — pero léela como mapa, no como conclusión
- ▶ Con dos categóricas: una tabla cruzada de frecuencias, vista como mapa de calor

Las trampas de la correlación



1. **Correlación $\neq$ causalidad**, y con suficientes variables siempre encuentras una correlación alta por azar
2. Pearson solo ve líneas: una U perfecta tiene correlación ≈ 0
3. Un solo outlier puede crear o destruir una correlación (Anscombe III y IV)

Reglas útiles

Nunca modifiques la base original.

- ▶ Puedes agregar columnas (`y_winsor`, `ba_imputada`, `es_outlier`), nunca borrar renglones, columnas o celdas del archivo fuente
- ▶ Todo filtro y toda imputación vive en el código, no en el archivo: así el análisis es reproducible y auditable
- ▶ Documenta cada decisión: cuántos renglones quitaste, con qué criterio y qué pasa si no los quitas
- ▶ Y la pregunta de cierre del EDA: ¿la conclusión sobrevive si tomo la otra decisión razonable?

Qué verificar cuando un agente hace EDA

1. **¿Graficó, o solo reportó estadísticas de resumen?** Un `describe()` sin histograma es Anscombe esperando a pasar. Pide la distribución de toda variable clave
2. **¿Usó media donde la variable es sesgada?** Compara media y mediana; si difieren mucho y el reporte dice “promedio”, el número está inflado por la cola
3. **¿Cuántos renglones sobrevivieron?** Exige `len(df)` antes y después de cada `dropna()` o filtro, y la comparación entre quienes se fueron y quienes se quedaron
4. **¿Justificó el mecanismo de faltantes?** Un `dropna()` o un `fillna(mean)` sin diagnóstico MCAR/MAR es una decisión escondida, no una limpieza

Qué verificar cuando un agente hace EDA

5. **¿Revisó códigos centinela y valores imposibles?** -99, ceros donde no puede haberlos, topes de codificación: `min()`, `max()` y `value_counts()` de los extremos
6. **¿Modificó la base original?** Cualquier archivo de datos que cambió de tamaño es una bandera roja: la limpieza va en el código
7. **¿La correlación que reporta es lineal y tiene sentido sustantivo?** Pídele el scatter, no el número