

VISUALIZACIÓN DE DATOS

Fernanda Sobrino

2026


¿Por qué visualizar?

John Snow y el cólera, Londres 1854



- ▶ Un brote mató a más de 500 personas en pocos días
- ▶ Snow tenía la teoría de que el agua transmitía la enfermedad, pero no podía demostrarlo
- ▶ Marcó en un mapa dónde moría la gente y dónde estaban las bombas de agua, y dibujó polígonos alrededor de cada bomba
- ▶ Las muertes se concentraban en una sola bomba: la de Broad Street
- ▶ La gráfica encontró la fuente del cólera

La composición del Congreso de EE.UU.






Quién habla en las películas de Disney

Disney Screenplay Dialogue, Broken-down by Gender

2,005 Screenplays: Dialogue Broken-down by Gender

Only High-Grossing Films: Ranked in the Top 2,500 by US Box Office*



Para qué sirve una gráfica

- ▶ **Explorar:** encontrar patrones que no sabías que estaban ahí (Snow)
 - ▶ **Entender:** darle forma a algo que ya medías (el Congreso)
 - ▶ **Explicar:** comunicar un hallazgo a alguien que no vio todas las películas (Disney)
 - ▶ **Preguntar:** casi siempre una buena gráfica genera más preguntas
-
- ▶ En este curso: `matplotlib` para control fino y `seaborn` para gráficas estadísticas rápidas
 - ▶ Regla práctica: usa la que sea **más sencilla** para lo que necesitas

Elegir la gráfica según la pregunta

Cuatro preguntas, cuatro familias

Si la pregunta es...	La gráfica es...
¿Cómo se reparte esta variable? (distribución)	histograma, densidad, boxplot
¿Cómo se mueven juntas estas dos? (relación)	dispersión, mapa de calor
¿Cuál grupo tiene más? (comparación)	barras, boxplot por grupo
¿Cómo cambió esto en el tiempo? (evolución)	línea, área
¿De qué está hecho el total? (composición)	barras apiladas, cascada, árbol

- ▶ Primero escribe la pregunta; después elige la gráfica. Nunca al revés
- ▶ Y elige una sola pregunta por gráfica: una gráfica que contesta tres preguntas no contesta ninguna

El mapa: de la pregunta a la función

Pregunta	Gráfica	Función
Distribución	histograma, densidad	<code>sns.histplot</code> , <code>sns.displot</code>
Comparación	boxplot por grupo	<code>sns.boxplot(order=...)</code>
Relación	dispersión	<code>sns.scatterplot</code> , <code>sns.regplot</code>
Evolución	línea	<code>sns.lineplot</code>
Conteo por categoría	barras	<code>sns.countplot</code> , <code>sns.barplot</code>
Los mismos datos, por grupo	<i>facets</i>	<code>sns.relplot(col=...)</code>
Gráficas distintas juntas	<i>subplots</i>	<code>plt.subplots(...)</code>

Cada propiedad visual carga información

- ▶ **Color** (hue) para categorías o para una escala continua — nunca las dos cosas a la vez
- ▶ **Forma** (style) para categorías cuando el color ya está ocupado
- ▶ **Tamaño** (size) solo para variables cuantitativas positivas
- ▶ **alpha** no codifica información: sirve para ver densidad donde los puntos se enciman
- ▶ **Posición** (los ejes) es lo que el ojo lee mejor: la variable más importante va ahí
- ▶ Si una propiedad visual no codifica nada, quítala

Trampas técnicas (las veremos en vivo)


1. **Sobregraficado:** con datos redondeados o categóricos, muchos puntos caen exactamente encima de otros — la gráfica enseña 100 donde hay 234. Se detecta comparando lo que ves con `len(df)`; se arregla con *jitter*, transparencia o resumen (hexágonos). El *jitter* mueve los puntos: sirve para ver, nunca para leer valores exactos
2. **La gráfica calcula cosas por ti:** histogramas y `countplot` agrupan y cuentan; `regplot` ajusta un modelo; `boxplot` decide qué es atípico. Eres responsable de ese cálculo aunque no lo hayas escrito: ¿qué ancho de caja?, ¿qué modelo?, ¿qué regla de outliers?

Trampas técnicas

3. **Facets no son subplots:** un *facet* divide los mismos datos por una variable, con ejes compartidos y comparable por construcción. Un *subplot* son lienzos independientes que pueden venir de bases y escalas distintas — pero el lector los va a comparar de todos modos. Si se comparan ponlo en el título.
4. **plt. se refiere a la última figura:** pyplot actúa sobre la figura que ya existe. `plt.show()` puede mostrarte la gráfica anterior y hacerte creer que tu código corrió. **Siempre declara tu figura** (`fig, ax = plt.subplots()`): es la diferencia entre una gráfica reproducible y una que depende del orden en que corriste las celdas


“Mintiendo” con gráficas

Barras que no miden nada



- ▶ Casos confirmados en Florida. Las barras están ordenadas **de mayor a menor altura**, pero los valores van $3,207 \rightarrow 3,822 \rightarrow 4,049 \rightarrow 3,494 \rightarrow 2,926$
- ▶ La altura no representa el número

Barras que no miden nada



- ▶ 0.7 % y 29.4 % se dibujan casi iguales; 56.9 % queda **más bajo** que 30.9 %
- ▶ Verificación de 10 segundos: toma dos barras y checa si la razón de alturas es la razón de los números

Cuando el eje miente



- Contagios en Cali: 218 se dibuja por debajo de 165. Los puntos no están en la escala que anuncia el eje

Cuando el eje miente


- ▶ Las tres versiones de esta trampa:
 - ▷ **Eje truncado:** empezar en 90 en vez de 0 convierte una diferencia de 2 % en un abismo
 - ▷ **Doble eje:** dos series con escalas distintas se cruzan donde el diseñador quiera; cualquier “correlación” es decorativa
 - ▷ **Eje no ordenado o con espaciamiento irregular:** años o categorías desordenados fabrican tendencias
- ▶ ¿El cero es obligatorio? En barras sí (la longitud es el dato). En líneas de series con variación pequeña, truncar puede ser legítimo — pero hay que decirlo

Misma cifra, distinto tamaño




- ▶ Petrolina, Brasil: 8 muertes en junio y 8 muertes en julio, dibujadas con alturas radicalmente distintas
- ▶ Las barras rojas comparten eje con las de casos (253 y 923), así que el ojo lee “las muertes se multiplicaron”
- ▶ El error de fondo: dos variables en escalas incomparables compartiendo el mismo espacio visual
- ▶ Si dos números iguales se ven distintos, la gráfica está rota — no importa qué tan profesional se vea

Área, perspectiva y pays



- ▶ Izquierda: 39.8 % se ve más grande que 60.2 %. La perspectiva 3D agranda lo que está al frente
- ▶ Derecha: 20 categorías, muchas en 0 %, imposibles de distinguir sin la leyenda
- ▶ Los humanos comparamos bien longitudes, mal áreas y pésimo volúmenes
- ▶ Por eso las gráficas de pay no se recomiendan: úsalas solo con dos o tres categorías, y aun así unas barras funcionan mejor

Partes que no son partes de un todo



Mortes de Covid-19 no Brasil

75% das vítimas tinham doenças associadas






Gráfico 01 • Fonte: Ministério da Saúde



- ▶ Izquierda: $70\% + 63\% + 60\% = 193\%$ en un pay. Eran tres preguntas distintas de opción múltiple, no una partición
- ▶ Derecha: comorbilidades en muertes por COVID. Una persona puede tener cardiopatía y diabetes, así que las categorías no son mutuamente excluyentes — la dona sugiere que sí
- ▶ Un pay o una dona exigen dos cosas: categorías excluyentes y exhaustivas. Si no se cumplen, usa barras y di explícitamente que un caso puede contarse dos veces

Conteos cuando la pregunta es de tasas



- ▶ Izquierda: el mapa colorea superficie, no votantes. Los estados grandes y despoblados dominan visualmente una elección que ganan las ciudades
- ▶ Derecha: proporción de admitidos por género en Berkeley. En conteos absolutos parecía discriminación; al normalizar por departamento el patrón se invierte (paradoja de Simpson)
- ▶ La pregunta siempre es la misma: ¿el denominador correcto está en la gráfica? Población, superficie, número de solicitantes, presupuesto

El orden y la escala también comunican



- Mismos datos. A la izquierda el orden es alfabético; a la derecha, por la variable de interés
- El orden alfabético sirve para buscar un elemento; el orden por valor sirve para comparar

El orden y la escala

- ▶ Barras horizontales cuando las etiquetas son largas: es más fácil leerlas que voltear la cabeza
- ▶ Ninguna de las dos gráficas miente, pero solo una responde “¿quién admite a más gente?”

Principios de honestidad gráfica

1. La longitud es el dato. Si usas barras, el eje empieza en cero, siempre
2. Un dato, una posición. La razón entre los tamaños dibujados debe ser la razón entre los números
3. Declara el denominador. Conteos y tasas contestan preguntas distintas; di cuál estás contestando
4. Etiqueta todo: unidades, periodo, fuente, y qué significa cada color

Principios de honestidad gráfica

5. Todo elemento visual codifica algo o sobra. Sin 3D, sin sombras, sin colores decorativos
6. El título dice el hallazgo, no la variable*: “El empleo cayó 12 % en 2020”, no “Empleo por año”
7. Enséñale tu gráfica a alguien sin contexto y pregúntale qué concluye. Si concluye algo que tú no querías decir, la gráfica está mal

Qué verificar cuando el agente grafique por ti

1. **¿El eje y empieza en cero?** En barras es obligatorio. Si el agente truncó el eje, pregúntale por qué y vuelve a leer la conclusión con el eje completo
2. **¿Las alturas corresponden a los números?** Toma dos elementos, divide sus valores y compara con la razón de tamaños en pantalla
3. **¿Conteos o tasas?** Si compara grupos de tamaños distintos con conteos absolutos, la gráfica mide población, no el fenómeno. Pide el denominador
4. **¿Hay doble eje, 3D, pay o mapa de áreas?** Los cuatro distorsionan por construcción. Pide la versión en barras y compara conclusiones

Qué verificar cuando el agente grafique por ti

5. **¿Los subplots comparten escala?** Si el agente hizo una rejilla de gráficas, verifica `sharey`; si no la comparten, no son comparables aunque estén lado a lado
6. **¿La afirmación del texto es la que muestra la gráfica?** El agente escribe conclusiones seguras; contrástalas contra los ejes, no con el texto
7. **¿Cuántos puntos hay realmente?** Compara lo que ves con `len(df)`: el sobregraficado esconde la mitad de los datos y la línea ajustada los da por vistos