
ML TEORÍA II

Clasificación a mano

Fernanda Sobrino

2026

Clasificar a mano

Hoy somos el algoritmo

- ▶ Vamos a clasificar casos sin computadora: con una regla, un lápiz y unas cuentas
- ▶ Dos algoritmos completos, paso a paso: K vecinos más cercanos y árboles de decisión
- ▶ Y dos más en intuición: regresión logística y Naive Bayes
- ▶ No es nostalgia. Es la única forma de saber después si `sklearn` te dio lo que pediste
- ▶ Regla del día: si no puedes hacerlo con diez renglones a mano, no puedes auditarlo con diez mil

K vecinos más cercanos

La idea: pregúntale a tus vecinos



- ▶ Llega una observación nueva (el cuadro negro). ¿Es una x o una o?
- ▶ KNN contesta: busca los k casos más parecidos que ya conoces y asume que se parece a sus vecinos(voto mayoritario)
- ▶ No hay entrenamiento: el “modelo” son los datos. Guardas la tabla y ya
- ▶ El costo se paga al predecir: para cada caso nuevo hay que medir la distancia a *todos* los anteriores

¿Qué es estar cerca?

$$distancia(x_q, x_i) = \sqrt{\sum_{r=1}^n (a_r(x_q) - a_r(x_i))^2}$$


Cada feature es una dimensión. Con dos establecimientos

$A = (12 \text{ empleados}, 3 \text{ años})$ y $B = (30, 1)$:


$$d(A, B) = \sqrt{(12 - 30)^2 + (3 - 1)^2} = \sqrt{324 + 4} = 18.1$$

- ▶ Fíjate quién manda: los empleados aportan 324 y los años aportan 4
- ▶ Hay otras distancias (Manhattan, coseno, Hamming para categóricas) — la euclidiana es la de default
- ▶ La distancia es una decisión de modelado: define qué significa “parecerse” en tu problema


La k cambia la respuesta



$k = 1$



$k = 3$



$k = 5$

- Con $k = 1$ el punto de la izquierda es x; con $k = 3$ y $k = 5$ es o. Los datos no cambiaron; la respuesta sí
- El mismo caso, tres clasificaciones distintas, y ninguna es “la verdadera”

¿Qué k elegir?

- ▶ k **chica**: la frontera sigue cada punto, incluido el ruido. Sobreajuste
- ▶ k **grande**: todo se promedia, la frontera se aplanan y los grupos pequeños desaparecen. Subajuste
- ▶ k **par** en un problema binario puede empatar: usa impares
- ▶ Se elige probando varios valores y midiendo el error — pero con validación, nunca con el test
- ▶ “Usé $k = 5$ ” no es una justificación; $k = 5$ es simplemente el default de `sklearn`

Todo tiene que ser numérico y comparable

id	nivel_escolaridad
1	secundaria
2	preparatoria
3	licenciatura
4	licenciatura
5	licenciatura
6	primaria

- ▶ **Categóricas:** no hay distancia entre “primaria” y “licenciatura”. Se convierten con *one-hot encoding*: una columna 0/1 por categoría
- ▶ Codificarlas como 1, 2, 3 le inventa al modelo una jerarquía y unas distancias que no existen

Todo tiene que ser numérico y comparable

- ▶ **Numéricas:** hay que escalar. Ingreso mensual (5,000 a 80,000) contra años de escolaridad (0 a 20):

$$(\Delta_{\text{ingreso}})^2 = 20,000^2 = 400,000,000 \quad (\Delta_{\text{escolaridad}})^2 = 15^2 = 225$$

- ▶ La escolaridad no es que pese poco: no existe. El modelo es un modelo de ingreso disfrazado
- ▶ Olvidar el escalamiento no produce ningún error: produce un resultado distinto y en silencio

KNN: fortalezas y trampas

A favor

- ▶ Premisa simple y fácil de explicarle a quien toma la decisión
- ▶ Captura fronteras irregulares sin que le digas la forma
- ▶ Resiste bien algunos datos raros

En contra

- ▶ Caro al predecir: distancia a todas las observaciones, cada vez
- ▶ Sin escalar da predicciones distintas, sin avisar
- ▶ Sufre con muchas features: en muchas dimensiones todo queda lejos de todo
- ▶ Elegir k depende del problema y de quien modela

El vecino más cercano de Carlos III



Nacidos en 1948 · criados en Inglaterra · casados dos veces · hijos famosos · ricos · viven en un castillo

- ▶ Con esas seis features, para KNN son **el mismo punto**: distancia casi cero, cada uno es el vecino más cercano del otro
- ▶ “Cercano” solo significa cercano **en las columnas que tú elegiste**; la distancia no ve nada más
- ▶ Antes de confiar en los vecinos, pregunta: ¿parecidos según qué? ¿Esas features capturan lo que importa para *esta* predicción?

Árboles de decisión


Titanic: la ficción contra los datos

“Mujeres y niños primero”: ¿Hombre? → si sí, ¿mayor de 10 años?


Grupo	Sobrevivieron	¿Predicción?
Mujeres	74 %	Sobrevive
Hombres mayores de 10	18 %	No sobrevive
Hombres de 10 o menos	22 %	...¿?

- ▶ El sexo separa muy bien. La edad, entre hombres, casi no separa nada: 18 % contra 22 %
- ▶ Ojo con el detalle: 177 pasajeros no tienen edad registrada y cayeron en el grupo de “10 o menos”. Esa decisión de limpieza mueve el número
- ▶ ¿Cómo mejoramos? Cambiar el corte de edad, o buscar otra variable. Un árbol hace exactamente eso, pero probándolas todas

Un buen corte deja nodos puros



Elementos homogéneos



Elementos heterogéneos

- ▶ Un nodo puro tiene solo un tipo de caso; uno impuro los tiene revueltos
- ▶ El algoritmo busca, entre todas las variables y todos los cortes, el que deja los grupos más puros

La entropía

La medida clásica de impureza es la entropía (Shannon, 1948):

$$Entropia = - \sum_i p_i \log_2 p_i$$

- ▶ Entropía 0 = todos iguales (una hoja). Entropía 1 = mitad y mitad (una moneda al aire)
- ▶ La ganancia de información es cuánta entropía elimina un corte. Gana el corte que más gana

El algoritmo, en seis pasos

1. Calcular la entropía de la variable a clasificar
 2. Calcular la entropía de la etiqueta respecto a una variable predictora
 3. Calcular la ganancia de información de esa variable
 4. Repetir 2 y 3 para cada variable predictora
 5. Elegir como nodo de decisión la de mayor ganancia
 6. Repetir con cada subconjunto resultante hasta que la entropía sea 0 o ya no haya con qué dividir
- Es todo. No hay más magia: contar, medir el desorden y quedarse con el corte que más lo reduce

Ejemplo a mano: ¿jugamos golf?

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

- ▶ 10 observaciones, dos predictoras (temperatura, humedad) y una etiqueta (jugar golf)
- ▶ Vamos a construir el árbol completo, a mano

Paso 1: la entropía de la etiqueta

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

$$Entropia(T) = -(6/10)\log_2(6/10) - (4/10)\log_2(4/10)$$

$$Entropia(T) = 0.9709506$$

 p -> Jugar golf
 q -> No jugar golf

- ▶ 6 de 10 sí jugamos, 4 de 10 no. Entropía = **0.971**: bastante revuelto (el máximo es 1)
- ▶ Este es el desorden de partida; todo corte se juzga contra este número

Paso 2: entropía dada la temperatura

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Temperatura Alta:

$$Entropia(Temp_A) = -(2/5)\log_2(2/5) - (3/5)\log_2(3/5)$$

$$Entropia(Temp_A) = 0.9709506$$

■ p -> Jugar golf
■ q -> No jugar golf

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Temperatura Normal:

$$Entropia(Temp_N) = -(4/5)\log_2(4/5) - (1/5)\log_2(1/5)$$

$$Entropia(Temp_N) = 0.5931569$$

■ p -> Jugar golf
■ q -> No jugar golf

- ▶ Temperatura **alta**: 5 casos, 2 sí y 3 no → entropía 0.971. Igual de revuelto que antes
- ▶ Temperatura **normal**: 5 casos, 4 sí y 1 no → entropía 0.593. Algo mejor

Paso 3: la ganancia de la temperatura

$$Ganancia(T, Temp) = Entropia(T) - Entropia(T, Temp)$$

$$Ganancia(T, Temp) = Entropia(T) - [P(Temp_A) * Entropia(Temp_A) + P(Temp_N) * Entropia(Temp_N)]$$

$$Ganancia(T, Temp) = 0.9709506 - (5/10 * 0.9709506 + 5/10 * 0.5931569)$$

$$Ganancia(T, Temp) = 0.1888969$$

- ▶ Ganancia = entropía original menos el **promedio ponderado** de las entropías de los hijos
- ▶ Partir por temperatura elimina **0.189** de desorden. Guárdalo y compáralo con la otra variable

Paso 4: la humedad

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Humedad Alta:

$$Entropia(H_A) = -(2/6)\log_2(2/6) - (4/6)\log_2(4/6)$$

$$Entropia(H_A) = 0.9182958$$

■ p -> Jugar golf
■ q -> No jugar golf

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Alta	Normal	Si
5	Alta	Normal	Si
6	Normal	Alta	Si
7	Normal	Alta	No
8	Normal	Normal	Si
9	Normal	Alta	Si
10	Normal	Normal	Si

Humedad Normal:

$$Entropia(H_N) = -(4/4)\log_2(4/4) - (0/4)\log_2(0/4)$$

$$Entropia(H_N) = 0$$

■ p -> Jugar golf
■ q -> No jugar golf

- ▶ Humedad **alta**: 6 casos, 2 sí y 4 no → entropía 0.918
- ▶ Humedad **normal**: 4 casos, los 4 sí → entropía **0**. Nodo perfectamente puro: eso es una hoja


Paso 5: gana la humedad

$$Ganancia(T, H) = Entropia(T) - Entropia(T, H)$$

$$Ganancia(T, H) = Entropia(T) - [P(H_A) * Entropia(H_A) + P(H_N) * Entropia(H_N)]$$

$$Ganancia(T, H) = 0.9709506 - (6/10 * 0.9182958 + 6/10 * 0)$$

$$Ganancia(T, H) = 0.419973$$



Paso 5: gana la humedad

- ▶ Humedad gana **0.420** contra 0.189 de temperatura → humedad es el **nodo raíz**
- ▶ La rama “normal” ya terminó: entropía 0, predicción “sí jugar”

Paso 6: seguimos con humedad alta

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Normal	Alta	Si
5	Normal	Alta	No
6	Normal	Alta	Si

	Temperatura	Humedad	Jugar Golf
1	Alta	Alta	No
2	Alta	Alta	No
3	Alta	Alta	No
4	Normal	Alta	Si
5	Normal	Alta	No
6	Normal	Alta	Si

Temperatura Alta:


$$Ganancia(T|A, Temp) = -(0/3)\log_2(0/3) - (3/3)\log_2(3/3)$$

$$Ganancia(T|A, Temp) = 0$$

■ p -> Jugar golf
■ q -> No jugar golf

- ▶ Quedan 6 observaciones. Volvemos al paso 2 **solo con ellas** y con las variables que faltan
- ▶ Temperatura alta: 3 casos, los 3 “no” → entropía 0, otra hoja
- ▶ Temperatura normal: 3 casos, 2 “sí” y 1 “no”. Ya no hay más variables: gana la mayoría

El árbol final



El árbol final

- ▶ Se lee de arriba hacia abajo, y cabe en una tarjeta
- ▶ Nota la última hoja: “sí” con 2 de 3. Una predicción no es una certeza, es la mayoría de un grupo pequeño
- ▶ Tres observaciones no son evidencia de nada. Un árbol sin límites llega a hojas de un solo caso

Clasifica este caso

Llega un día nuevo: **humedad alta, temperatura normal**. ¿Jugamos?

- ▶ Raíz: ¿humedad? Alta → nos vamos a la derecha
- ▶ Siguiente: ¿temperatura? Normal → hoja de la derecha
- ▶ Predicción: **sí jugar**, con una confianza de 2/3

- ▶ Esto es lo que hace `predict()` con cada renglón: bajar por el árbol y devolver la etiqueta de la hoja
- ▶ Y esto es lo que puedes explicarle a un inspector, a un juez o a un comité — la razón por la que los árboles siguen vivos

Profundidad: sobreajuste y subajuste

- ▶ Si dejas al árbol crecer sin límite, sigue partiendo hasta que cada hoja tenga un solo caso: memoriza y no generaliza
- ▶ Si lo limitas demasiado, no alcanza a capturar el patrón: subajuste
- ▶ Los dos hiperparámetros que importan: `max_depth` (qué tan hondo) y `min_samples_leaf` (mínimo de casos por hoja)
- ▶ No hay valor correcto: dependen del problema y de cuántos datos tengas
- ▶ Otro problema: los árboles son inestables. Cambia unas cuantas observaciones y el árbol se ve completamente distinto

La misma persona, dos hojas distintas



59 años, 364 días → «riesgo bajo»



60 años, 0 días → «riesgo alto»

- ▶ Un corte es una frontera **dura**: con ¿edad ≥ 60 ?, la misma persona cae en hojas opuestas con un día de diferencia
- ▶ Es el espejo de la trampa de KNN: KNN convierte a dos personas distintas en el mismo punto; el árbol convierte a la misma persona en dos casos opuestos
- ▶ Casi nada en el mundo cambia de golpe en un umbral, pero el árbol solo sabe dibujar escalones: cerca del corte, desconfía de la predicción

Del árbol al bosque, y dos modelos más


Random Forest: el promedio de muchos árboles

- ▶ Si un árbol es inestable, hagamos **muchos** y promediamos. Un bosque aleatorio es un ensamble de árboles
- ▶ La diversidad se fabrica a propósito, de dos formas:
 1. Cada árbol se entrena con una **muestra aleatoria con reemplazo** de los datos (*bagging*)
 2. En cada corte, cada árbol solo puede ver un **subconjunto aleatorio de features**
- ▶ La predicción final es el **voto** de todos los árboles (o el promedio de sus probabilidades)
- ▶ Ganamos mucho poder predictivo y baja la varianza. Perdemos la regla legible: 500 árboles no se explican en una tarjeta
- ▶ La regla del curso: si el bosque no le gana claramente al árbol, quédate con el árbol

Pregúntale al público

- ▶ En *¿Quién quiere ser millonario?* había dos comodines: llamar a un amigo experto o preguntarle al público
- ▶ El amigo experto acertaba cerca del **65 %** de las veces; el público, cerca del **91 %**
- ▶ Muchas opiniones mediocres pero **diversas**, promediadas, le ganan a una sola opinión inteligente
- ▶ Eso es un Random Forest: cada árbol es un miembro del público que vio datos distintos y features distintas
- ▶ La condición escondida: los errores deben ser **independientes**. Si todo el público repite el mismo rumor — o todos los árboles dependen de la misma columna dominante — el promedio no arregla nada. Por eso el bosque fabrica la diversidad a propósito

Regresión logística, en intuición



- ▶ Queremos una **probabilidad**, y una recta se sale de $[0, 1]$. La logística la “aplasta” con una curva en forma de S
- ▶ Cada variable tiene un **coeficiente interpretable**: cuánto mueve la probabilidad, en qué dirección
- ▶ Sale un número entre 0 y 1 — y para actuar hace falta elegir un corte (el tema de la próxima clase)
- ▶ Es la línea base obligatoria de casi cualquier problema de clasificación

Naive Bayes, en intuición

- ▶ Le da la vuelta a la pregunta con el teorema de Bayes:

$$P(y \mid X) = \frac{P(X \mid y) P(y)}{P(X)}$$

- ▶ En vez de “¿qué tan probable es que sea spam dadas estas palabras?”, pregunta “¿qué tan probable es ver estas palabras en un spam?” — y eso sí se puede contar
- ▶ Es **naive** (ingenuo) porque supone que las features son **independientes** entre sí. Casi nunca es cierto: “gratis” y “oferta” aparecen juntas
- ▶ Aun así funciona sorprendentemente bien, es rapidísimo y sirve con pocos datos
- ▶ Sus probabilidades están mal calibradas: úsalas para **ordenar** casos, no como probabilidades reales

Qué verificar cuando el agente hace esto

1. **¿Escaló antes de usar KNN?** Es la trampa silenciosa: sin escalar el código corre igual y clasifica por la variable con los números más grandes
2. **¿De dónde salió la k o la `max_depth`?** Si no hay una curva de validación detrás, es el default. Pídele que lo diga
3. **¿Codificó las categóricas con one-hot o les puso 1, 2, 3?** La segunda inventa un orden y unas distancias que no existen
4. **¿Puso límites al árbol?** Sin `max_depth` ni `min_samples_leaf` el árbol memoriza; pide la profundidad y el tamaño de las hojas

Qué verificar cuando el agente hace esto (cont.)

5. **¿Cuántas observaciones hay en cada hoja?** Una regla apoyada en tres casos no es una regla, y el árbol la dibuja igual de bonita
6. **¿Puedes seguir a mano una predicción?** Toma un caso, bájalo por el árbol y compara con `predict`: si no coinciden, algo está mal en el pipeline
7. **¿Interpretó la importancia de variables como causalidad?** Los agentes escriben “X causa Y” con toda naturalidad; la importancia solo dice cuánto ayudó a partir los nodos