
ML TEORÍA III

¿Qué tan bueno es mi modelo?

Fernanda Sobrino

2026

¿Comparado con qué?

“El modelo tiene 92 %” – ¿y?

- ▶ Un número solo no dice nada. Un 92 % puede ser un modelo excelente o un modelo bastante malo
- ▶ Tres preguntas antes de mirar cualquier métrica:
 1. ¿92 % de qué? ¿Qué está contando exactamente esa métrica?
 2. ¿Comparado con qué? ¿Cómo se resuelve el problema hoy?
 3. ¿Qué error está escondiendo? Toda métrica resume, y resumir es tirar información
- ▶ Hoy: qué mide cada métrica, cuál mentira cuenta cada una, y por qué **elegir la métrica es una decisión de política pública**

Baserate y baseline

Baserate: la tasa actual de lo que queremos predecir

- ▶ Si el 2 % de los establecimientos tiene una violación grave, ese 2 % es el baserate
- ▶ Es lo que queremos afectar con la acción, y cambia según cuándo lo midas

Baseline: el desempeño de cómo se hace el trabajo hoy, medido con la misma métrica

- ▶ Las inspecciones se hacen al azar
- ▶ Las inspecciones se hacen por antigüedad del establecimiento
- ▶ Las inspecciones siguen una regla que alguien escribió en 2011

Sin baseline, cualquier número suena bien.

La matriz de confusión

Dos formas de equivocarse

Predicción / Real	Etiqueta positiva	Etiqueta negativa
Etiqueta positiva	Verdaderos positivos	Falsos positivos
Etiqueta negativa	Falsos negativos	Verdaderos negativos



- ▶ **Falso positivo** (error tipo I): dije que sí y era no. Molesté a quien no debía
- ▶ **Falso negativo** (error tipo II): dije que no y era sí. Se me escapó
- ▶ Los cuatro números son la materia prima: todas las métricas de clasificación salen de esta tabla
- ▶ Antes de calcular nada, mira los cuatro. Ninguna métrica sustituye ver la matriz completa

¿Cuál error es peor?

Un falso positivo es más grave cuando...

- ▶ Una persona inocente es condenada: apelar es lento, caro y muchas veces no ocurre
- ▶ Se le retira un apoyo a un hogar que sí calificaba
- ▶ La intervención es punitiva: multar, sancionar, detener, negar

Un falso negativo es más grave cuando...

- ▶ Un diagnóstico de cáncer se pierde: un falso positivo se desmiente con la siguiente prueba; un falso negativo avanza en silencio
- ▶ Un establecimiento peligroso nunca se inspecciona
- ▶ La intervención es asistiva y el costo de intervenir de más es bajo

Esta pregunta se contesta antes de modelar, no después.

Ejercicio en clase

ID entidad	¿Alto riesgo? (real)	Predicción
1	Sí	No
2	No	No
3	Sí	No
5	Sí	Sí
15	No	Sí
24	No	No
35	Sí	No
47	Sí	Sí
98	Sí	No
190	Sí	Sí

Llena la matriz de confusión. ¿Cuántos VP, FP, FN y VN hay?

La matriz del ejercicio

	Real: Sí	Real: No
Predijo: Sí	VP = 3	FP = 1
Predijo: No	FN = 4	VN = 2

- ▶ 7 entidades de alto riesgo, y el modelo encontró 3
- ▶ Solo se equivocó una vez señalando de más
- ▶ Los cuatro números ya cuentan la historia: este modelo es cauteloso y se le escapa más de la mitad
- ▶ Si el objetivo es no dejar pasar riesgos, es un mal modelo. Si el objetivo es no molestar de más, no parece tan malo

Accuracy

$$accuracy = \frac{TP+TN}{TP+FP+TN+FN}$$

- ▶ Porcentaje de observaciones clasificadas correctamente. Es la métrica que todo el mundo reporta primero
- ▶ En el ejercicio: $(3 + 2)/10 = 0.5$. Una moneda al aire
- ▶ Trata todos los errores como si costaran lo mismo — y casi nunca cuestan lo mismo
- ▶ Y tiene un problema peor cuando la clase positiva es rara

Accuracy engaña: el ejemplo

100,000 establecimientos. 2,000 tienen una violación grave (**baserate** = 2 %).


Modelo propuesto: “*ninguno tiene violación*”. Una línea de código, cero inteligencia.

Métrica	Valor
Accuracy	98 %
Falsos positivos	0
Falsos negativos	2,000
Cobertura de violaciones	0 %

- ▶ 98 % de accuracy y cero utilidad: no encuentra ni un solo caso de los que importan
- ▶ Con clases desbalanceadas, el accuracy mide qué tan rara es la clase positiva, no qué tan bueno es el modelo
- ▶ Y desbalanceados están casi todos los problemas de política pública

Precisión y cobertura

Precisión y cobertura



Precisión y cobertura

- ▶ **Precisión** = $\frac{VP}{VP + FP}$: de los que señalé, ¿cuántos eran?
- ▶ **Cobertura** (*recall*) = $\frac{VP}{VP + FN}$: de los que había, ¿a cuántos encontré?
- ▶ Precisión responde por quien paga la inspección. Cobertura responde por quien se queda sin ella

Las dos se pelean

- ▶ Subir el umbral (señalar solo los casos más seguros): sube la precisión, baja la cobertura
- ▶ Bajarlo (señalar a más): sube la cobertura, baja la precisión
- ▶ Los dos extremos son inútiles y los dos se ven bien en una métrica:
 - ▷ “Todos tienen cáncer”: cobertura 100 %, precisión igual al baserate
 - ▷ Señalar un solo caso, el más obvio: precisión 100 %, cobertura ~0 %

F1

$$F = 2 \cdot \frac{\textit{precision} \cdot \textit{recall}}{\textit{precision} + \textit{recall}}$$

- ▶ Es la media armónica de precisión y cobertura: un solo número que castiga fuerte si alguna de las dos está mal
- ▶ Sirve para comparar modelos rápido y con clases desbalanceadas es mucho mejor que el accuracy
- ▶ Le da el mismo peso a los dos errores. Si en tu problema un FN cuesta más que un FP, F1 no ayuda mucho


Las métricas del ejercicio

Con VP = 3, FP = 1, FN = 4, VN = 2:

Métrica	Cuenta	Valor
Accuracy	$(3 + 2)/10$	0.50
Error tipo I (FP)	$1/10$	0.10
Error tipo II (FN)	$4/10$	0.40
Precisión	$3/4$	0.75
Cobertura	$3/7$	0.43
F1	media armónica	0.55


- Precisión alta, cobertura baja: cuando señala, casi siempre acierta; pero deja pasar a la mayoría
- ¿Es bueno? **Depende de si el costo está en inspeccionar de más o en no inspeccionar**

La curva precisión-cobertura



- ▶ No hay un punto: hay una curva. Cada punto es un umbral distinto del mismo modelo
- ▶ Se lee así: “si quiero 60 % de cobertura, mi precisión será de 81 %”

La curva ROC (Receiver Operating Characteristic)



- ▶ Grafica la tasa de verdaderos positivos contra la de falsos positivos, para todos los umbrales posibles
- ▶ Mejor modelo = curva que se pega a la esquina superior izquierda
- ▶ La diagonal es el azar: un modelo que tira volados

AUC: qué mide y qué esconde

- ▶ **AUC** es el área bajo la curva ROC: 0.5 = azar, 1.0 = perfecto
- ▶ Mide qué tan bien el modelo separa las dos clases: la probabilidad de que un positivo tomado al azar tenga mayor puntaje que un negativo
- ▶ Es independiente del umbral y de la escala
- ▶ Ignora el costo asimétrico de los errores**
- ▶ Sirve para comparar modelos entre sí.

Presupuesto: métricas @k

En política pública siempre hay una k

$$precision@k = \frac{\# TP@k}{\# recomendaciones@k} \qquad recall@k = \frac{\# TP@k}{\text{Total de TPs}}$$

- ▶ No tienes 100,000 inspecciones: tienes 100 inspectores y seis meses
- ▶ La clasificación completa da igual. Lo único que importa son los k casos que sí vas a atender
- ▶ El procedimiento: ordena por puntaje, corta en k , y calcula precisión y cobertura ahí
- ▶ k es tu presupuesto, tu personal, tus camas de hospital, tus becas. La restricción real
- ▶ **precision@k** mide qué tan eficientes somos con el recurso; **recall@k**, cómo lo estamos repartiendo entre todos los que lo necesitan

precision@k y recall@k, con números

100,000 establecimientos, 2,000 con violación (2 %), 100 inspectores.

Estrategia	precision@100	recall@100
Al azar (baseline)	2 %	0.1 %
Modelo, top 100	62 %	3.1 %
Modelo, top 200 (con el doble de inspectores)	55 %	5.5 %

- ▶ El modelo es 31 veces más eficiente que el azar. Ese es el número que se le presenta a la autoridad
- ▶ Pero fíjate en la cobertura: con 100 inspectores el máximo posible es 5 % ($100/2,000$). El resto no es culpa del modelo, es del presupuesto
- ▶ Duplicar inspectores baja la precisión y sube la cobertura: siempre. Esa es la conversación real

Cómo se calcula

```
ranking = (pd.DataFrame({"score": y_scores, "real": y_test.values})
            .sort_values("score", ascending=False))


k = 100
top_k = ranking.head(k)

precision_at_k = top_k["real"].mean()           # eficiencia
recall_at_k    = top_k["real"].sum() / y_test.sum() # cobertura
```

► Requiere predict_proba, no predict: necesitas el **puntaje** para poder ordenar

El umbral y quién decide

Del puntaje a la acción



- El modelo devuelve **0.37**. Eso no es una decisión: es un insumo
- Entre el puntaje y la acción hay una regla de decisión: un umbral, o un top k
- Esa regla no vive en el modelo. Vive en la política, en el presupuesto y/o en la ley

Elegir el umbral no es estadística es política

- ▶ El 0.5 de `predict()` es un default arbitrario, no un hallazgo. Casi nunca es el umbral que quieres
- ▶ Mover el umbral no cambia el modelo: redistribuye los errores entre falsos positivos y falsos negativos
- ▶ Y eso es redistribuir daño entre personas concretas: quién es inspeccionado de más, quién se queda sin apoyo
- ▶ Esa decisión no la puede tomar el modelo, ni quien lo programó, ni la IA: la toma quien responde por el programa
- ▶ El trabajo técnico es poner sobre la mesa la curva y las opciones. El trabajo político es elegir un punto y defenderlo

La misma métrica, distinta por grupo




Figure 4: Recidivism, evaluation results per group value for selected model (Precision@150 = 0.73).

Cómo leer la gráfica


Auditoría por grupo (herramienta *Aequitas*) de un modelo de reincidencia que señala a los $k = 150$ de mayor riesgo. Conteos por grupo: Prev. = proporción positiva de verdad (su baserate), PP = señalados por el modelo, FP/FN los conocidos.

Barra	Nombre	En palabras
PPrev	prevalencia predicha	qué proporción del grupo fue señalada ($PP \div \text{tamaño}$)
PPR	proporción de señalados	de todos los señalados, cuántos caen en este grupo
FDR	tasa de falso descubrimiento	de los señalados del grupo, cuántos no eran ($= 1 - \text{precisión}$)
FOR	tasa de falsa omisión	de los no señalados, cuántos sí eran
FPR	tasa de falsos positivos	de los que no eran, a cuántos señaló
FNR	tasa de falsos negativos	de los que sí eran, a cuántos dejó ir ($= 1 - \text{cobertura}$)

La misma métrica, distinta por grupo

- ▶ El desempeño global esconde desempeños muy distintos por edad, género o grupo poblacional
- ▶ Aquí un modelo con $\text{precision@150} = 0.73$ tiene tasas de falsos positivos y falsos negativos que varían fuerte entre grupos
- ▶ Un modelo puede ser “bueno” en promedio y sistemáticamente peor con quienes ya estaban peor

¿Qué métrica de equidad?



¿Qué métrica de equidad? (cont.)

- ▶ No existe “el modelo justo”: existen **definiciones de equidad incompatibles entre sí**, y hay que elegir una
- ▶ La pregunta clave es si la intervención es **punitiva** (te puede dañar) o **asistiva** (te ayuda)
 - ▷ Punitiva → cuida los **falsos positivos**: no castigar de más a un grupo
 - ▷ Asistiva → cuida los **falsos negativos**: no dejar fuera a quien más lo necesita
- ▶ Elegir la métrica es elegir a quién proteger. **La métrica codifica valores** — y alguien tiene que firmarla

Qué verificar cuando el agente hace esto

1. **¿Reportó la matriz de confusión completa, o solo un número?** Pide los cuatro valores; un accuracy suelto no es un resultado
2. **¿Cuál es el baserate?** Si la clase positiva es el 2 %, el accuracy es una trampa por construcción — pide precisión y cobertura
3. **¿Contra qué baseline compara?** Sin la regla actual (o al menos el azar) medida con la misma métrica, no hay evidencia de mejora
4. **¿Hay presupuesto en el problema?** Si hay k inspectores, becas o camas, la métrica es precision@ k y recall@ k — no AUC

Qué verificar cuando el agente hace esto (cont.)

5. **¿De dónde salió el umbral?** Si es 0.5, es el default de `predict`, no una decisión. Pide la curva precisión–cobertura y quién eligió el punto
6. **¿Desagregó por grupo?** Pide las métricas por sexo, edad, región o grupo relevante: el promedio esconde el daño
7. **¿La métrica corresponde al costo real del error?** Pregúntale explícitamente qué cuesta más aquí, un FP o un FN, y verifica que la métrica que reportó castigue **ese** error