
APRENDIZAJE NO SUPERVISADO: CLUSTERING


Introducción a la ciencia de datos

Fernanda Sobrino

2026

Aprendizaje no supervisado

De supervisado a no supervisado



- ▶ Supervisado: tenemos pares (X, y) y aprendíamos f tal que $f(X) \approx y$
- ▶ No supervisado: **solo tenemos X** . No hay etiqueta, no hay respuesta correcta
- ▶ Y por lo tanto: **no hay conjunto de prueba**. No podemos medir “qué tan bien le atinamos”
- ▶ Familias: agrupamiento, detección de anomalías, reducción de dimensionalidad (PCA)

Qué es agrupar (clustering)

- ▶ **Análisis de agrupamiento:** partir un conjunto de observaciones en subconjuntos (grupos o *clusters*)
- ▶ Dos condiciones:
 - ▷ los datos de un mismo grupo deben **parecerse entre sí**
 - ▷ los datos de grupos distintos deben ser **diferentes**
- ▶ Usos típicos: segmentación de beneficiarios, zonas de alta demanda, tipologías de municipios, detección de fraude
- ▶ La pregunta incómoda desde el minuto uno: *¿parecerse en qué?*

Cómo trabajaremos: estas slides son el mapa

- ▶ **Estas slides son el resumen conceptual**; todo el código se ve, se corre y se rompe en vivo en los notebooks
- ▶ Esta clase se acompaña de **dos notebooks**, en este orden:
 - ▷ `notebooks/Clustering_K-means_Hierarchical.ipynb` (blobs sintéticos, microarrays de tumores)
 - ▷ `notebooks/Clustering_DBSCAN.ipynb` (medias lunas, viajes en taxi de Nueva York)
- ▶ El ritmo de la clase: una idea aquí → al notebook a hacerla → de regreso solo para el siguiente concepto
- ▶ Para estudiar: los notebooks son la referencia completa; estas slides son el repaso rápido de antes del examen

Distancias: qué significa “parecido”

$$\text{dist}(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + \dots + (x_{ir} - x_{jr})^2}$$

$$\text{dist}(\mathbf{x}_i, \mathbf{x}_j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ir} - x_{jr}|$$

- ▶ **Euclidiana:** la línea recta. El default de casi todo
- ▶ **Manhattan:** como caminar por una ciudad cuadriculada; menos sensible a valores extremos
- ▶ **Coseno:** mide dirección, no magnitud (texto). **Jaccard:** para conjuntos y variables binarias
- ▶ Cambiar la distancia cambia los grupos. No es un detalle técnico: es una **decisión sustantiva**

Escalar aquí no es opcional

$$z = \frac{x_i - \mu}{\sigma}$$

$$z = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

- ▶ En supervisado, escalar era necesario para *algunos* modelos. En clustering **todo** se basa en distancias
- ▶ Si mezclas “población” (millones) con “tasa de pobreza” (0–1), la población es la única variable que existe
- ▶ No hay train/test: se escala con **todos** los datos, y hay que documentarlo
- ▶ Cuidado adicional: escalar mete a los outliers al mismo rango, no los elimina

K-means

El algoritmo

$$c(i) = \operatorname{argmin} \|x_i - m_k\|^2$$

$$c_i = \frac{1}{d_i} \sum_{j=1}^{d_i} x_j$$

1. Eliges k y colocas k centroides iniciales
 2. **Asignas** cada punto al centroide más cercano
 3. **Mueves** cada centroide al promedio de los puntos que le tocaron
 4. Repites 2 y 3 hasta que nada cambia
- El centroide representa al grupo: es su punto promedio (puede no ser una observación real)

Inicialización: por qué importa

- ▶ K-means minimiza la **inercia** (suma de distancias al cuadrado a su centroide), pero solo garantiza un **mínimo local**
- ▶ Con centroides iniciales malos, converge a una partición mala y se ve perfectamente razonable
- ▶ k-means++ elige centroides iniciales alejados entre sí, con probabilidad proporcional a la distancia al cuadrado
- ▶ También se controla cuántas veces repetir el algoritmo con distintos arranques: se queda con la de menor inercia
- ▶ Sin fijar la semilla, **dos corridas dan grupos distintos** — y los números del reporte cambian

¿Cuántos grupos? El codo

- ▶ La inercia **siempre** baja al aumentar k (con $k = n$ vale cero): no se puede “maximizar”
- ▶ Se corre K-means para $k = 1, 2, \dots, 10$ y se grafica la inercia contra k
- ▶ Buscamos el punto donde deja de bajar rápido: el **codo**
- ▶ Problema honesto: muchas veces **no hay codo**. En el ejemplo de tumores no lo había y se eligió $k = 3$ por criterio experto
- ▶ El codo sugiere, no decide


¿Cuántos grupos? La silueta

$$s = \frac{b - a}{\max(b - a)}$$

¿Cuántos grupos? La silueta (cont.)

- ▶ Para cada punto: a = distancia media a los de su grupo, b = distancia media al grupo vecino más cercano
- ▶ Va de -1 a $+1$: cerca de 1 está bien acomodado, cerca de 0 está en la frontera, negativo probablemente está en el grupo equivocado
- ▶ La **silueta promedio** resume todo en un número, y por eso es peligrosa
- ▶ Un promedio alto puede esconder un grupo entero con silueta negativa: mira el **diagrama** de silueta, no solo el número

K-means supone grupos esféricos



- ▶ K-means busca grupos **redondos y de tamaño parecido**, porque solo usa distancia al centroide
- ▶ Con grupos alargados, anidados o de densidades muy distintas, parte los datos donde no hay corte
- ▶ Y lo hace sin quejarse: la inercia baja igual y la gráfica se ve limpia
- ▶ La inercia más baja **no** es el mejor agrupamiento

Clustering jerárquico

Aglomerativo: la idea

- ▶ No eliges k de entrada: construyes una **jerarquía completa** de agrupamientos
- ▶ Aglomerativo (de abajo hacia arriba):
 1. Cada observación es su propio grupo
 2. Se fusionan los **dos grupos más cercanos**
 3. Se repite hasta que queda un solo grupo
- ▶ Ventaja sobre K-means: los grupos quedan **anidados** — con 4 grupos no se rompe la estructura de 3
- ▶ Además da un orden parcial de las observaciones, útil para interpretar

Linkage: distancia entre grupos

- ▶ El algoritmo necesita una distancia entre *grupos*, no entre puntos. Esa regla es el **linkage**:
- ▶ **Single**: distancia entre los dos puntos más cercanos → grupos largos y encadenados
- ▶ **Complete**: entre los dos más lejanos → grupos compactos
- ▶ **Average**: promedio de todos los pares → intermedio, suele ser el más estable
- ▶ **Ward**: minimiza el aumento de varianza dentro del grupo (parecido en espíritu a K-means)
- ▶ El **linkage** cambia el resultado tanto como cambiar de algoritmo — es una decisión, no un default

El dendrograma

- ▶ El resultado del algoritmo es una **matriz de fusiones**: cada renglón dice qué dos grupos se unieron, a qué distancia, y de qué tamaño quedó el grupo nuevo
- ▶ El dendrograma es el dibujo de esa matriz
- ▶ La **altura** de cada rama es la distancia a la que se fusionaron: ramas altas = grupos muy distintos
- ▶ Los índices mayores al número de observaciones se refieren a grupos creados en pasos anteriores

El dendrograma (cont.)

- ▶ **Correlación cofenética:** qué tanto las distancias del dendrograma reproducen las distancias reales
 - ▷ cerca de 1, el árbol es fiel; baja, el dibujo está deformando los datos
- ▶ En el ejemplo de tumores, *average* dio la cofenética más alta y *single* produjo grupos encadenados inútiles
- ▶ Sirve para **elegir el linkage**: no es un número decorativo

Cortar el árbol

- ▶ Cortar horizontal el dendrograma a una altura da una partición concreta
- ▶ Se puede cortar a una **altura** (una distancia) o pidiendo directamente un **número de grupos**
- ▶ Cortar más abajo = más grupos, más chicos
- ▶ **Ojo:** el dendrograma no dice dónde cortar. Elegir la altura es la misma decisión que elegir k , solo que ahora se ve como un dibujo elegante

DBSCAN

Densidad: núcleo, frontera y ruido

- ▶ Idea distinta: un grupo es una **región densa** de puntos, sin importar su forma
- ▶ Dos parámetros: `eps` (radio del vecindario) y `min_samples` (mínimo de vecinos, *minpts*)
- ▶ Tres tipos de punto:
 - ▷ **núcleo (core)**: tiene al menos `min_samples` vecinos dentro de `eps`
 - ▷ **frontera**: está dentro del radio de un núcleo, pero no tiene suficientes vecinos propios
 - ▷ **ruido**: ni una cosa ni la otra — etiqueta —1
- ▶ Lo importante: **DBSCAN no obliga a que todo punto pertenezca a un grupo**

Qué gana y qué pierde DBSCAN

- ▶ **No** hay que decirle cuántos grupos: los descubre (y descubre cuántos hay)
- ▶ Encuentra grupos de forma arbitraria — medias lunas, anillos, calles
- ▶ Es el único de los tres que puede decir “esto no pertenece a ningún grupo”: la etiqueta -1 es información, no un error
- ▶ Lo que pierde: no tiene forma de asignar un punto nuevo. Para eso se entrena un clasificador (por ejemplo KNN) sobre los puntos núcleo
- ▶ Y hereda el problema de siempre: los dos parámetros los eliges tú

Elegir eps y minpts

- ▶ Todo el resultado depende de estos dos números, y no hay un método automático
- ▶ Con eps muy chico, casi todo es ruido; con eps muy grande, todo es un solo grupo
- ▶ La forma honesta es **razonar la densidad del dominio**: en el ejemplo de taxis de NY, se estimó la densidad promedio de viajes en Manhattan (60 km²), se fijó como objetivo 10× esa densidad y de ahí salió $\text{minpts} = \text{densidad} \times \text{área}(\text{eps})$
- ▶ **HDBSCAN** generaliza DBSCAN: encuentra grupos de **densidades distintas** en los mismos datos y evita fijar un solo eps

Mapa y trampas

El mapa: algoritmo, cuándo usarlo, qué revisar

Algoritmo	Cuándo usarlo	Qué revisar siempre
K-means	grupos redondos, muchos datos, k razonable de antemano	semilla, número de arranques, codo y silueta
Jerárquico	pocos datos, quiero ver la estructura anidada	el linkage elegido y la correlación cofenética
DBSCAN	formas raras, hay ruido de verdad, no sé cuántos grupos hay	eps, minpts y qué porcentaje quedó como ruido

- ▶ Los tres necesitan escalar antes. Los tres devuelven grupos aunque no los haya
- ▶ Ninguno de los tres tiene un conjunto de prueba: la validación es sustantiva, no estadística

Tres trampas (las veremos en vivo en los notebooks)

1. **El promedio esconde el desastre:** una silueta promedio decente puede convivir con un grupo entero de silueta negativa. Solo el diagrama por observación lo enseña — el número solo, no
 2. **La distancia se calcula en las unidades equivocadas:** en el ejemplo de taxis, las coordenadas vienen en Web Mercator, donde un “metro” no mide lo mismo en toda la ciudad. Hay que reproyectar **antes** de medir, o eps no significa nada
 3. **El linkage bonito y el linkage útil no son el mismo:** *single linkage* produce dendrogramas espectaculares y grupos encadenados inservibles. La cofenética es la que decide, no el dibujo
- Regla transversal: si no fijaste la semilla, el reporte no es reproducible — y los grupos del jueves no son los del martes

AI notebook

Lo que vamos a hacer en

Clustering_K-means_Hierarchical.ipynb

1. **Demostración de K-means** sobre blobs sintéticos: centroides, asignación, predecir observaciones nuevas
 2. **Distancia a los centroides** como “soft clustering”: qué tan seguro está el algoritmo
 3. **Inicialización**: comparar arranques aleatorios contra k-means++ y ver cómo cambia el resultado
 4. **Elegir k** : la curva de inercia (el codo) y el diagrama de silueta, lado a lado
 5. **Cuando K-means falla**: grupos alargados y de densidades distintas
 6. **Caso aplicado — microarrays de tumores**: K-means como línea base, comparar los cuatro linkages, leer la matriz de fusiones, la correlación cofenética, el dendrograma y el corte
- Los **ejercicios están marcados en el notebook** — se hacen ahí, en el momento

Lo que vamos a hacer en Clustering_DBSCAN.ipynb

1. **Demostración de DBSCAN** sobre medias lunas: núcleo, frontera y ruido
 2. **El efecto de eps**: la misma base con $\text{eps}=0.05$ y con $\text{eps}=0.2$, y por qué una funciona
 3. **Predecir puntos nuevos** entrenando un KNN sobre los puntos núcleo
 4. **Caso aplicado — taxis de NY**: 12 millones de viajes, explorar la demanda por hora y visualizar densidad
 5. **Proyecciones**: por qué Web Mercator no sirve para medir distancias y cómo reprojectar a UTM
 6. **Razonar eps y minpts** desde la densidad del dominio, correr DBSCAN y mapear los hotspots
- Los **ejercicios están marcados en el notebook** — se hacen ahí, en el momento

¿Son reales los grupos?

Cuándo falla cada uno

Algoritmo	Supone	Falla cuando
K-means	grupos esféricos, tamaño similar	formas alargadas, densidades distintas, outliers
Jerárquico	que la jerarquía existe	datos grandes (costoso); <i>single linkage</i> encadena
DBSCAN	densidad uniforme	densidades muy distintas; eps mal elegido

- ▶ Todos sufren con **muchas dimensiones**: ahí todas las distancias se parecen entre sí y “cercano” pierde significado
- ▶ Ninguno tiene manera interna de decirte que se equivocó

El algoritmo siempre devuelve grupos

- ▶ Dale ruido puro a K-means con $k = 4$ y te va a entregar cuatro grupos, con sus centroides y su gráfica de colores
- ▶ No existe la salida “aquí no hay estructura” (DBSCAN es la única excepción parcial: puede declarar todo ruido)
- ▶ Cómo distinguir estructura real de partición arbitraria:
 - ▷ ¿La silueta es decente, o apenas arriba de 0?
 - ▷ ¿Los grupos **sobreviven** al cambiar semilla, escalamiento, algoritmo o quitar una variable?
 - ▷ ¿Se distinguen en variables que **no** usaste para agrupar?
 - ▷ ¿Alguien que conoce el tema los reconoce y les puede poner nombre?

El riesgo de política pública

- ▶ Escenario real: agrupar municipios y **asignar fondos por grupo**
- ▶ Si los grupos no son reales, acabas dando tratamientos distintos a municipios idénticos, con una justificación técnica impecable
- ▶ Un cluster **no es** una categoría del mundo: es el resultado de tus decisiones de distancia, escala y k

El riesgo de política pública (cont.)

Agravantes típicos:

- ▶ La frontera entre grupos es arbitraria, pero el presupuesto es discreto: dos municipios casi idénticos caen de lados distintos
- ▶ Los grupos reproducen la variable que dominó la distancia (casi siempre, tamaño de población)
- ▶ Se les pone nombre — “municipios rezagados” — y el nombre se vuelve real aunque el grupo no lo sea

Qué verificar cuando el agente hace esto

1. **¿Escaló antes de calcular distancias?** Sin escalar, el agrupamiento es de la variable con los números más grandes
2. **¿Fijó `random_state` y reportó `n_init`?** Si no, los grupos cambian entre corridas y el reporte no es reproducible
3. **¿De dónde salió k ?** Pide el codo y la silueta, y que diga qué tan claro fue — “elegí $k=4$ ” sin evidencia no vale
4. **¿Probó estabilidad?** Otra semilla, otro algoritmo, quitar una variable: si los grupos se deshacen, no existen

Qué verificar cuando el agente hace esto (cont.)

5. **¿Perfiló los grupos?** Medias por grupo y tamaño de cada uno; un grupo con 3 observaciones no es un segmento
6. **¿Le puso nombres?** Ojo con las etiquetas interpretativas que el agente inventa — verifica que el perfil numérico las respalde
7. **¿Con DBSCAN, cuánto quedó como ruido?** Si es 60 % de los datos, eps está mal, no es que los datos sean raros